

MÉMOIRE

pour obtenir le grade de Master délivré par

Université Paris 8 Vincennes à Saint Denis

Mention *Informatique*

Parcours *Big data et Fouille de données*

présenté et soutenu publiquement par

Angélique DELEVINGNE

le 11 septembre 2024

Comptage d'arbres et segmentation des couronnes
grâce au Deep Learning

Directeur de mémoire : Rakia JAZIRI

Maître de stage : Aude CARRO ET ERWANN HOUZAY

Stage effectué à : TOTALENERGIES

COMUE Paris Lumières
Laboratoire d'Intelligence Artificielle et Science des Données
Laboratoire Paragraphe

M
A
S
T
E
R

Sommaire

Remerciements	5
Introduction	7
I Problématique et état de l'art	9
1 Contexte de résolution du problème	13
2 Le problème à résoudre	27
3 État de l'art : Datascience pour le comptage et la segmentation d'objets dans les images	45
II Système réalisé	59
4 Implémentation du système	63
5 Expérimentations et résultats	81
6 Conclusion	91
Conclusion	91
Glossaire	93
Table des figures	95
Table des matières	99

Remerciements

Je tiens tout d'abord à remercier toute l'équipe du service TENBS et de la R&D de TotalEnergies pour son accueil chaleureux, son soutien tout au long de mon stage et les connaissances qu'ils ont partagées avec moi durant toute cette période. Je remercie Aude Carro et Erwann Houzay pour la confiance qu'ils m'ont accordée ainsi que leur soutien tout au long de ma mission.

Je tiens également à remercier les enseignants du Master 2 Big Data qui m'ont permis d'apprendre, de comprendre et de créer des programmes informatiques spécialisées en data science. J'ai aimé la diversité des cours et les projets que j'ai pu réaliser à l'Université Paris 8. Grâce à l'enseignement fort en pratique, j'ai pu m'adapter avec agilité à un contexte, un environnement métier et aux attentes de la mission qui m'a été confiée.

Ces connaissances et cette agilité m'ont permis d'être plus performante lors de mon stage en entreprise. Elles m'ont permis de trouver des solutions auxquelles je n'aurai peut-être pas pensé auparavant.

Un grand merci !

Introduction

J'ai effectué mon stage de Master 2 Big Data, de début février à fin juillet 2024 au sein de l'entreprise TotalEnergies située dans le quartier d'affaires de La Défense.

TotalEnergies est une société française multi-énergie mondialement connue. Elle produit et fournit de l'énergie telle que : pétrole, biocarburant, gaz et électricité. Elle se présente comme le 1er fournisseur alternatif d'énergie de France avec comme ambition d'être un acteur majeur de la transition énergétique. J'ai effectué mon stage dans la branche Exploration-Production de l'entité TotalEnergies Nature Based Solutions (TENBS) et la branche One Tech de l'entité Recherche et Développement (R&D).

L'entité TENBS finance, développe et gère des exploitations qui séquestrent du carbone. TotalEnergies mène des actions afin de compenser les émissions de gaz à effet de serre générées par ses activités.

La branche One Tech regroupe 3 400 ingénieurs, scientifiques et techniciens. OneTech réunit différentes entités : la customer line, la technical line et la R&D. La technical line soutient directement les activités commerciales de la customer line. La R&D soutient la technical line. Ensemble, ils collaborent pour renforcer l'innovation et concevoir des projets industriels majeurs. One Tech a pour rôle de fournir un appui technique et une expertise aux filiales opérationnelles du groupe, avec la R&D en soutien de cette expertise.

La mission principale, qui m'a été confiée, consiste à développer un algorithme basé sur du Deep Learning pour le comptage des arbres et la segmentation de leurs couronnes.

J'ai choisi de faire ce stage car ce sujet me permettait d'approfondir les acquis de ma formation en intelligence artificielle. De plus, j'avais envie de renforcer mes compétences sur les traitements et analyse de données de type images.

J'ai également eu une mission annexe de Data Management au sein de la branche TENBS. L'objectif étant de dresser un inventaire des données produites par l'équipe et de réfléchir à une stratégie de gestion des données pour permettre une amélioration de la productivité de l'équipe. Au cours de cette mission, j'ai été à l'écoute des besoins métiers.

Première partie

Problématique et état de l'art

Table des matières

1	Contexte de résolution du problème	13
1	Introduction	14
2	Entreprise	14
3	Gouvernance	16
4	Les services	17
5	Les équipes	19
6	Répartition du travail	22
7	La démarche et Planning	24
8	Conclusion	25
2	Le problème à résoudre	27
1	Objectif métier	28
2	Objectif technique	29
3	Données	29
4	Analyse des données	36
5	Ingénierie des caractéristiques	39
6	Augmentation des données	42
7	Décomposition du problème	42
8	Conclusion	43

3 État de l'art : Datascience pour le comptage et la segmentation d'objets dans les images	45
1 Introduction	46
2 Prétraitement et traitement des données	46
3 Travaux connexes	47
4 Evaluation des résultats	55
5 Conclusion	57

Chapitre 1

Contexte de résolution du problème

Sommaire

1	Introduction	14
2	Entreprise	14
3	Gouvernance	16
4	Les services	17
5	Les équipes	19
5.1	Equipe TENBS	19
5.2	Equipe R&D	21
5.3	Autres parties prenantes	21
6	Répartition du travail	22
7	La démarche et Planning	24
8	Conclusion	25

1 Introduction

La mission, qui m'a été confiée, consiste à utiliser le Deep Learning pour faire de la segmentation des couronnes et le comptage des arbres sur des images provenant de satellite. Le projet s'appelle GreenMapper.



Fig. 1.1 : Logo du projet GreenMapper

2 Entreprise

Crée en 1924, le groupe Total a décidé en 2021 de changer de nom pour marquer son investissement dans les énergies renouvelables propres et ainsi devenir TotalEnergies.

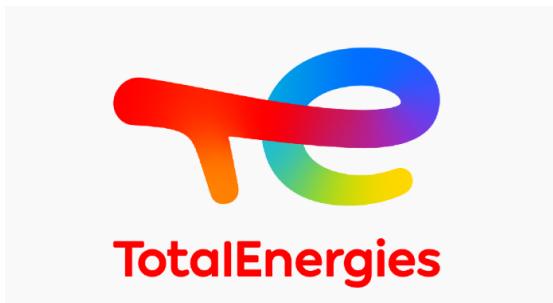


Fig. 2.1 : Logo TotalEnergies

TotalEnergies est une compagnie de production et de fourniture multi-énergies mondiale : pétrole et biocarburants, gaz naturel et gaz verts, renouvelables et électricité. Son objectif est de satisfaire la demande mondiale en énergie tout en réduisant ses émissions carbones. Elle s'est engagée pour la neutralité carbone en 2050. Pour cela l'ensemble de la société avec ses 102 milles collaborateurs s'est mobilisée pour une énergie toujours plus abordable, plus propre, plus fiable et accessible au plus grand nombre.

La société est présente dans plus de 130 pays avec 160 nationalités représentées et plus de 740 métiers.

TotalEnergies est présente dans ces différentes régions du monde :

- Afrique : 40 pays
- Amérique : 17 pays
- Europe : 31 pays
- Moyen-Orient : 9 pays



Fig. 2.2 : Présence de TotalEnergies dans les différentes régions du monde

TotalEnergies peut opérer mondialement en s'appuyant localement sur des collaborateurs qui connaissent les spécificités de chaque pays. La collaboration mondiale est source à la fois de solutions innovantes et d'opportunités nouvelles.

En 2022, l'entreprise Total a généré un chiffre d'affaires record de 281 milliards de dollars américains, après un fort ralentissement économique subit en 2020 à cause du COVID-19.

Le chiffre d'affaires de TotalEnergies en 2023 s'est élevé à 237,13 milliards de dollars américains. Cela représente une baisse par rapport à l'année précédente.

En 2022, les prix du pétrole et du gaz à leur plus haut niveau de la décennie ont soutenu les résultats financiers de l'entreprise, atteignant la valeur la plus élevée sur la période considérée.

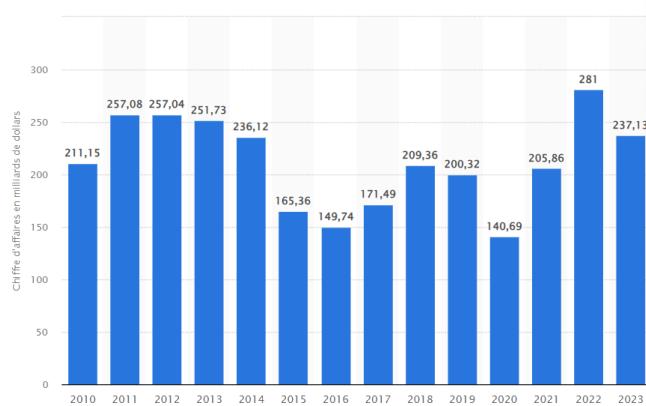


Fig. 2.3 : Chiffre d'affaire de TotalEnergies

3 Gouvernance

Depuis octobre 2014, le président-directeur général de TotalEnergies est Patrick Pouyanné. Sous la responsabilité de Patrick Jean Pouyanné, le Comité exécutif (COMEX) constitue l'instance de direction de TotalEnergies. Une seconde instance, le Comité de performance de la Compagnie, a pour mission l'examen, l'analyse et le pilotage des résultats HSE (Hygiène, sécurité et environnement), financiers et opérationnels.

Chez TotalEnergies, la gouvernance s'articule autour du Conseil d'administration et de la Direction générale. Le rôle du Conseil d'administration est de définir les orientations stratégiques de TotalEnergies, avec l'appui de quatre comités (Comité d'audit, Comité de gouvernance et d'éthique, Comité des rémunérations et Comité Stratégie & RSE). Il est composé de 14 administrateurs aux profils variés, dont neuf membres indépendants. Le Conseil d'administration veille à l'application des meilleures pratiques de gouvernance et se réfère dans cette démarche au Code AFEP-MEDEF de gouvernement d'entreprise des sociétés cotées.

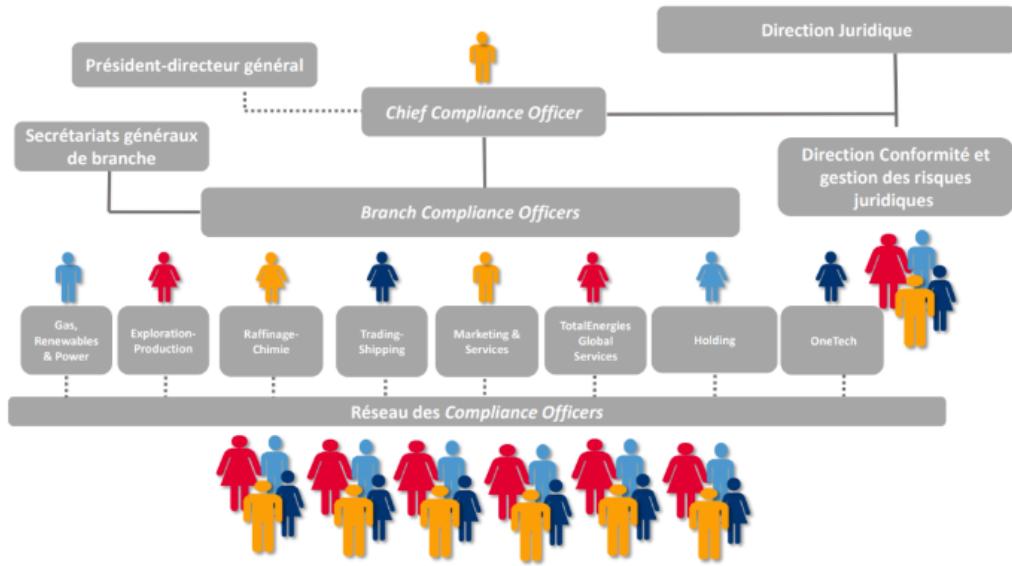


Fig. 3.1 : Organisation TotalEnergies

4 Les services

Ma mission s'est déroulée dans le service **Nature Based Solutions (TENBS)** et le service **Recherche et Développement (R&D)**.

4.0.1 TENBS

TENBS a été créé en juin 2019. Ce service finance, développe et gère des exploitations qui séquestrent du carbone et compensent les émissions carbone de TotalEnergies. Ces exploitations tirent parti de la préservation ou de la capacité à absorber les émissions des agroécosystèmes. Ces solutions sont dites « basées sur la nature ». Ce service travaille à compenser les émissions de gaz à effet de serre (GES) générées par les activités de TotalEnergies.

TENBS a pour ambition de compenser toutes les émissions résiduelles dites de Scope 1 et 2 de l'entreprise à compter de 2030. Cela équivaut à environ 5 à 10 millions de tonnes équivalent CO₂ par an.

Actuellement, TENBS fait partie de la nouvelle direction Neutralité Carbone qui a été créée en septembre 2021 dans le service d'Exploration Production (EP). Cette direction englobe également au même niveau que TENBS les activités : Carbon Footprint Reduction (CFR) et Carbon Capture and Storage (CCS).

TENBS développe des solutions basées sur la nature avec des partenaires et des communautés locales. Elle possède et développe un portefeuille diversifié d'opérations intégrées et durables produisant des crédits carbone certifiés, des revenus et des co-bénéfices à partir de chaînes de valeur enracinées localement et partagées. Lorsque l'équipe développe un projet, les conditions de vie locale s'améliorent, la dégradation des espaces recule et les émissions carbone avec elle. La recherche de l'équilibre des usages rend possible une transition juste.

En 2022, TotalEnergies a noué de nouveaux partenariats et contrats avec des acteurs reconnus au Gabon, au Pérou, en Asie du Sud-Est et au Guatemala. Le budget annuel consacré à ces projets est de 100 M de dollar. Le volume cumulé de crédits carbone espéré est de 45 millions à 2030 et 69 millions sur la durée de vie des projets. La réalisation des projets déterminera les quantités finales de crédit carbone obtenues.

4.0.2 R&D

En septembre 2021, TotalEnergies a réuni au sein de la branche OneTech 3 400 ingénieurs, scientifiques et techniciens en vue de renforcer la capacité d'innovation et les compétences à concevoir et conduire de grands projets industriels, en tirant parti de l'excellence opérationnelle des équipes.

La mission de cette entité est très complète et stratégique. Voici les points clés de sa mission :

1. Élaborer la stratégie R&D : Cette entité est responsable de définir la direction et les priorités de la recherche et du développement (R&D) pour l'ensemble du groupe. Cela implique de prendre en compte les besoins actuels et futurs, ainsi que les opportunités technologiques.
2. Élaborer le budget de R&D : Elle consolide les propositions des différentes branches de l'entreprise et prend des décisions sur l'allocation des ressources pour les projets de R&D. Cela nécessite une analyse minutieuse des coûts, des avantages et des risques.
3. Piloter les programmes transverses : Elle coordonne les initiatives de R&D qui transcendent les divisions ou les départements. Cela peut inclure des projets collaboratifs, des plateformes technologiques communes ou des synergies entre différentes équipes.
4. Identifier les innovations technologiques de rupture : L'entité surveille les développements technologiques et identifie les opportunités de rupture (c'est-à-dire des innovations qui changent fondamentalement la donne). Elle explore comment ces innovations peuvent bénéficier à l'ensemble du groupe.

5. Coordonner les grands partenariats : Elle gère les collaborations stratégiques avec d'autres entreprises, universités, instituts de recherche, etc. Ces partenariats peuvent accélérer l'innovation et permettre d'accéder à des ressources externes.
6. Représenter le Groupe dans les instances extérieures : L'entité joue un rôle de représentation dans les forums, les conférences et les groupes de travail liés à la R&D. Cela permet de partager les connaissances, d'influencer les politiques et de rester à la pointe des développements technologiques.

En somme, cette entité est au cœur de la stratégie d'innovation et de croissance du groupe, en veillant à ce que la R&D soit alignée sur les objectifs globaux.

À l'appui de sa stratégie de transformation, TotalEnergies a fortement réorienté sa R&D au cours des dernières années, puisque depuis 2021, plus de 50% de la R&D est consacrée aux nouvelles énergies (renouvelables, biomasse, batteries...) et à la baisse de l'empreinte environnementale (méthane, CCUS, eau, biodiversité...).

Pour accélérer cette transformation, la R&D a noué des partenariats avec des industriels et le monde académique. Ils investissent par ailleurs dans l'expertise digitale et l'Intelligence Artificielle. Par exemple, TotalEnergies utilise des outils tels que Copilot, qui est un outil qui utilise l'intelligence artificielle générative par Microsoft ou encore les solutions IA de Google Cloud.

La R&D développe ses propres solutions internes pour accélérer la transition énergétique de la société et celle de ses clients. La R&D ne développe que des solutions qu'elle considère clef pour le business. Par exemple : l'IA est utilisée pour optimiser la production d'hydrocarbures, la logistique et la gestion des stocks. Les algorithmes d'optimisation aident à réduire les coûts et à maximiser les rendements.

La branche OneTech réunit ainsi l'ensemble des compétences techniques toutes énergies confondues.

5 Les équipes

5.1 Équipe TENBS

L'équipe TENBS est composée de différents membres :

- Le Vice-President Nature Based Solutions,
- La Directrice adjointe,

- Des Chefs de projets,
- Des Managers selon les régions des projets,
- L'Equipe technique appelée « Expertise carbone, foresterie » dans laquelle j'ai réalisé mon stage.

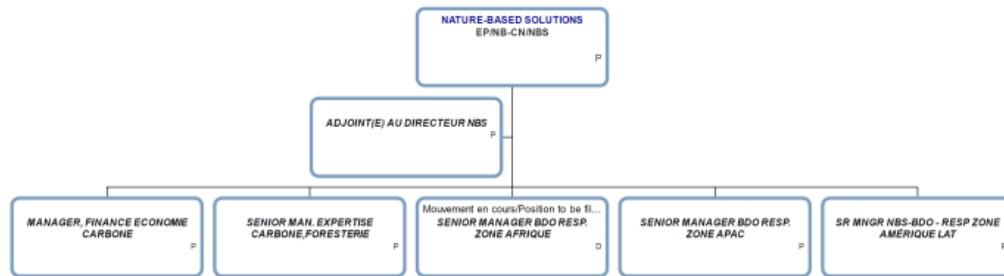


Fig. 5.1 : Organisation TENBS

L'équipe travaille très activement pour trouver, analyser, investir et suivre des projets écologiques partout dans le monde qui répondent à l'objectif de la société.

Lors des réunions d'équipe, j'ai constaté combien l'équipe TENBS est très investie, réactive et dynamique pour rechercher activement tout à la fois de nouveaux projets et de nouveaux partenaires.

5.2 Équipe R&D

L'équipe de la R&D fait partie de l'entité OneTech qui regroupe d'autres branches :

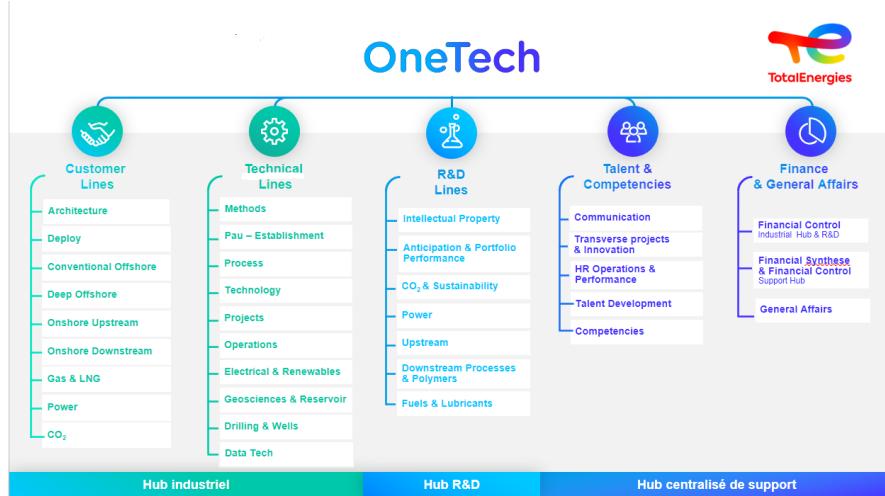


Fig. 5.2 : Organisation OneTech

Au sein de la R&D, j'étais dans l'équipe Upstream qui a pour objectif d'améliorer l'efficacité opérationnelle des activités d'Exploration-Production. Upstream aide à réduire les émissions de gaz à effet de serre, à diminuer les coûts, à réduire les cycles d'études tout en contribuant à l'amélioration de la sécurité.

L'équipe R&D - Upstream est responsable de la maîtrise d'oeuvre du projet de TENBS. TENBS est responsable de la maîtrise d'ouvrage.

5.3 Autres parties prenantes

Ce projet en interne est commun à TENBS, GeoSpatial et à la R&D. L'entité GeoSpatial de TotalEnergies est experte des données géospatiales. Ce projet fait également contribuer en externe l'entreprise Google.

TENBS, le client final, a confié à GeoSpatial de la branche One Tech la réalisation de son projet. La R&D est intervenue pour soutenir GeoSpatial dans ce nouveau secteur. La R&D a sollicité Google pour développer une solution d'IA et son infrastructure Cloud nécessaire au traitement d'images sur de vastes ensembles de données et utilisable pour d'autres projets futurs.

Ce partenariat permet à l'équipe R&D de monter en compétences sur ces nouveaux sujets et d'avoir la maîtrise d'une solution en interne. De plus l'objectif est de se doter d'une chaîne de traitement et de gestions de la données avec des outils Cloud. La participation de Google aide au transfert de ces compétences.

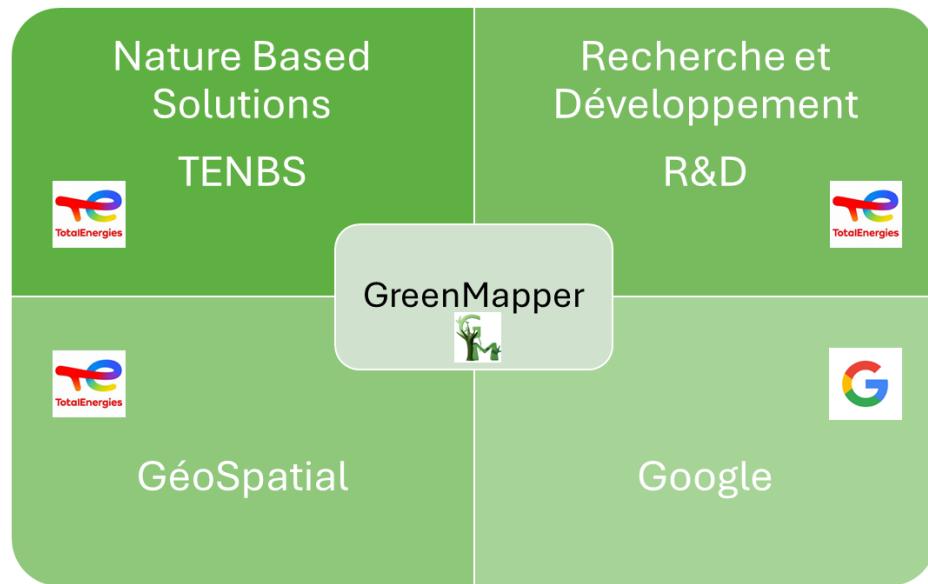


Fig. 5.3 : Parties prenantes du projet GreenMapper

6 Répartition du travail

Ma tutrice de stage est Aude Carro, experte en carbone forêt et agriculture et Erwann Houzay, spécialiste en traitement d'image. Ils ont été mes interlocuteurs privilégiés pour comprendre les besoins métier et la partie technique. Nous avons fait des points hebdomadaires spécifiques pour suivre l'avancée de mes travaux.

Mon temps de travail s'est réparti de la façon suivante :

- La mission principale de datascience a pris 75% du temps,
- La mission annexe de data management a pris 25% du temps.

La mission principale, appelée GreenMapper, implique la participation de différentes personnes :

- **TENBS** : L'équipe TENBS est le client final du projet. Elle indique les attentes du projet. Elle finance pour partie ses activités.
- **R&D** : L'équipe de la R&D analyse les besoins de TENBS, s'occupe de la conception, de la réalisation et du déploiement du projet ; tout en assurant son financement. Ce projet étant innovant, l'équipe cherche également à acquérir de nouvelles connaissances. La R&D a été le maître d'ouvrage de Google.

- **GeoSpatial** : L'équipe GeoSpatial est en charge d'acquérir les données satellites auprès d'AirBus et de drones.
- **Google** : L'équipe de Google joue un rôle essentiel en fournissant des outils Google Cloud, en concevant l'architecture cloud et en gérant la partie IA du projet.

Pendant le projet Green Mapper, nous avons tenu des réunions hebdomadaires pour suivre les avancées. A la demande de mon tuteur de stage, j'ai étendu le dataset d'images, en créant des images synthétiques. J'ai développé une solution de Deep Learning sur divers jeux de données. Dans la répartition des tâches de ce projet collaboratif, Google est responsable de l'implémentation IA et TotalEnergies responsable d'assurer le flux de données. Je n'ai pas pu collaborer directement avec Google au développement de la partie IA. Cette partie a été mise sous la responsabilité de Google.

7 La démarche et Planning

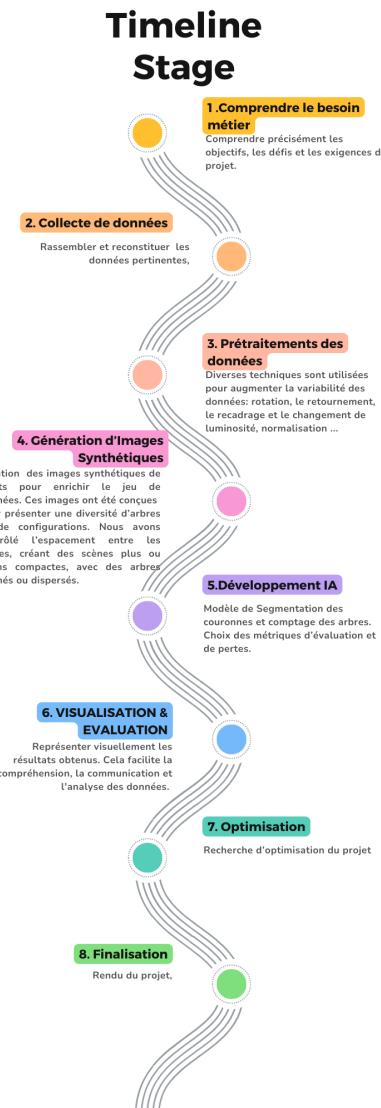


Fig. 7.1 : Etapes du stage

8 Conclusion

Le projet GreenMapper va solliciter l'équipe technique la R&D sur des technologies innovantes.

Chapitre 2

Le problème à résoudre

Sommaire

1	Objectif métier	28
2	Objectif technique	29
3	Données	29
3.1	Listes des données	29
3.2	Acquisition des données	31
4	Analyse des données	36
4.1	Inconvénients pour l'acquisition	36
4.2	Les données en quelques chiffres	37
4.3	Format multiple	38
5	Ingénierie des caractéristiques	39
5.1	Élimination des données manquantes	39
5.2	Données à reconstituer	39
6	Augmentation des données	42
7	Décomposition du problème	42
8	Conclusion	43

1 Objectif métier

L'objectif métier de TENBS est d'investir dans des initiatives de compensation carbone qui reposent sur la préservation et/ou l'augmentation de la capacité de stockage de carbone des agroécosystèmes. Cet objectif s'inscrit dans l'engagement de TotalEnergies : d'atteindre la neutralité carbone de la société d'ici 2050.

Pour cela TENBS investit dans les projets AFOLUs (Agriculture, Foresterie et Autres Usages des Terres) générant des crédits carbone.

Les projets AFOLUS consistent en la plantation d'arbres, la gestion durable des forêts, des pratiques agricoles durables, l'utilisation de techniques agricoles efficaces et des mesures pour réduire les émissions de GES.

Le stage repose sur les besoins de TENBS. Le projet est opéré par la branche One Tech - Technical Line- GeoSpatial. La R&D les soutient pour définir et réaliser un ensemble d'outils qui leur permet de tenir qui leur permettra d'améliorer leur productivité pour tenir leurs objectifs métiers.

TENBS a investi dans de nombreux projets forestiers à l'international. dont des activités de plantation d'arbres à grande échelle. Le monitoring de ce type de projet est un enjeu important pour :

- Vérifier que le nombre d'arbres plantés est en accord avec les objectifs du projet,
- Suivre l'évolution de la biomasse des arbres et s'assurer que les objectifs de stockage de carbone du projet sont bien respectés.

En foresterie traditionnelle, ce monitoring est basé sur un échantillonnage terrain statistique au cours duquel un opérateur va venir mesurer le nombre d'arbre. TENBS a des projets sur de grande étendue qui rendent cette tache longue, fastidieuse et couteuse. Elle nécessite en plus de se déplacer.

L'utilisation de l'imagerie drone, aérienne et/ou satellite est un des moyens les plus efficaces pour réaliser ce type monitoring. Les images satellites permettent de couvrir de manière répétées et systématiques de très larges étendues. L'image est un bon moyen mais nécessite une bonne résolution et de l'automatisation pour l'extraction des arbres. Une automatisation pour un monitoring continu va permettre de déduire le nombre d'arbres plantées, leur taux de mortalité ainsi que la vitesse de croissance.

L'objectif de mon stage est d'éliminer ces contraintes terrain en mobilisant des approches par apprentissage profond ou deep learning pour automatiser le processus de détection des arbres et des contours de houpiers à partir d'images à diverses résolutions.

2 Objectif technique

L'objectif technique de mon stage est de compter le nombre d'arbre sur des images.

Pour automatiser le comptage des arbres sur des images, il faut conjointement résoudre une tache de segmentation des couronnes des arbres.

Données en entrées :

- Images aériennes Opensource
- Images drones et satellites appartenant à TENBS sur un projet en opération

Données en sorties :

- Images des masques des arbres
- Nombre d'arbres d'une image

L'objectif technique du projet se résume en plusieurs étapes :

- Récupérer les images des différentes résolutions et sources
- Analyser et normaliser les données,
- Faire un modèle de segmentation des couronnes des arbres
- Faire un comptage des arbres
- Présenter les résultats à l'équipe,
- Optimiser : Donner des pistes d'amélioration.

3 Données

3.1 Listes des données

Avec le service TENBS et la R&D, nous avons récupéré plusieurs données provenant de différentes sources, à différentes résolutions et formats.

Nous avons accès à un ensemble d'images aérienne en OpenSource pour le Danemark et la Finlande. Voici le nombre de données dont nous disposons :

- **Danemark** : 84 images contenant un total de 19 645 arbres.
- **Finlande** : 19 images contenant un total de 4 773 arbres.

- **TENBS** : 5 images contenant un total de 7 797 arbres

De plus, nous avons des données de drones provenant de TENBS dans le cadre d'un projet opérationnel.

Pour chaque image, j'ai récupéré cette liste de données :

- **Images canaux Rouge, Vert et Bleu** : Il y a 3 fichier PNG représentant la même image. Ces canaux représentent l'intensité lumineuse dans chaque plage de couleur respective.
- **Masque d'arbre** : C'est un fichier JSON qui contient les points des polygones qui délimite les couronnes des arbres.
- **Image infrarouge** : Les images infrarouges donnent des informations sur la végétation. Elles permettent de surveiller son état de santé.

Pour chaque image, j'ai fait un programme pour générer les nouvelles données :

- **Image couleur** : A l'aide des 3 fichier RVB j'ai recomposé l'image en couleur.
- **Carte de densité** : La carte de densité se réfère à un point situé au centre de chaque arbre
- **Image masque** : À partir des polygones qui délimitent les couronnes des arbres, j'ai créé une image binaire où les arbres sont en blanc et le reste est en noir

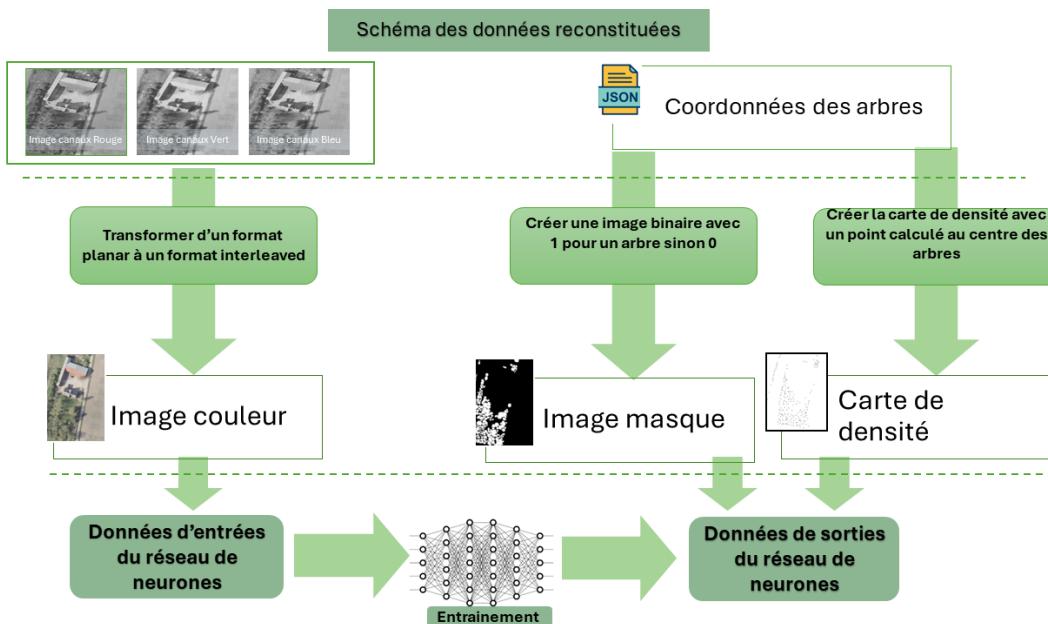


Fig. 3.1 : Préparation des données

3.2 Acquisition des données

3.2.1 Imagerie satellite

Les satellites, placés en orbite autour de la Terre, sont dotés de capteurs optiques sophistiqués (caméras) qui enregistrent des images en lumière visible et infrarouge. La résolution de ces images peut varier considérablement : certains satellites sont capables de capturer des détails extrêmement fins, mesurés en centimètres, tandis que d'autres fournissent des images avec une résolution plus grossière, allant jusqu'au décamètre.

Ces capteurs peuvent être classés en deux catégories : multispectraux et hyperspectraux. Les capteurs multispectraux capturent des images dans plusieurs bandes de longueurs d'onde spécifiques, tandis que les capteurs hyperspectraux enregistrent dans des centaines de bandes étroites, permettant une analyse plus détaillée et précise des caractéristiques de la surface terrestre. Les capteurs peuvent également être actifs ou passifs. Les capteurs passifs détectent la lumière naturelle réfléchie par la Terre, tandis que les capteurs actifs émettent leur propre signal, tel qu'un radar ou un lidar, puis mesurent le signal réfléchi pour créer des images.

Les données collectées par les satellites sont envoyées vers des stations terrestres via des signaux radio. Une fois reçues, ces données brutes doivent être traitées pour devenir utilisables. Ce processus de traitement comprend plusieurs étapes

critiques :

- **Élimination du bruit** : Le bruit électronique, causé par des interférences dans les circuits électroniques du satellite, et le bruit optique, résultant de distorsions dans les systèmes de lentilles, sont supprimés pour améliorer la qualité des images.
- **Calibration** : Les données sont calibrées pour corriger les variations dans la réponse des capteurs et pour assurer que les images représentent fidèlement les conditions observées. Cela inclut des calibrations radiométriques (pour ajuster l'intensité des signaux) et géométriques (pour corriger les distorsions spatiales).
- **Géoréférencement** : Les images sont positionnées avec précision sur la surface de la Terre à l'aide de systèmes de positionnement global (GPS) et d'autres techniques de cartographie.

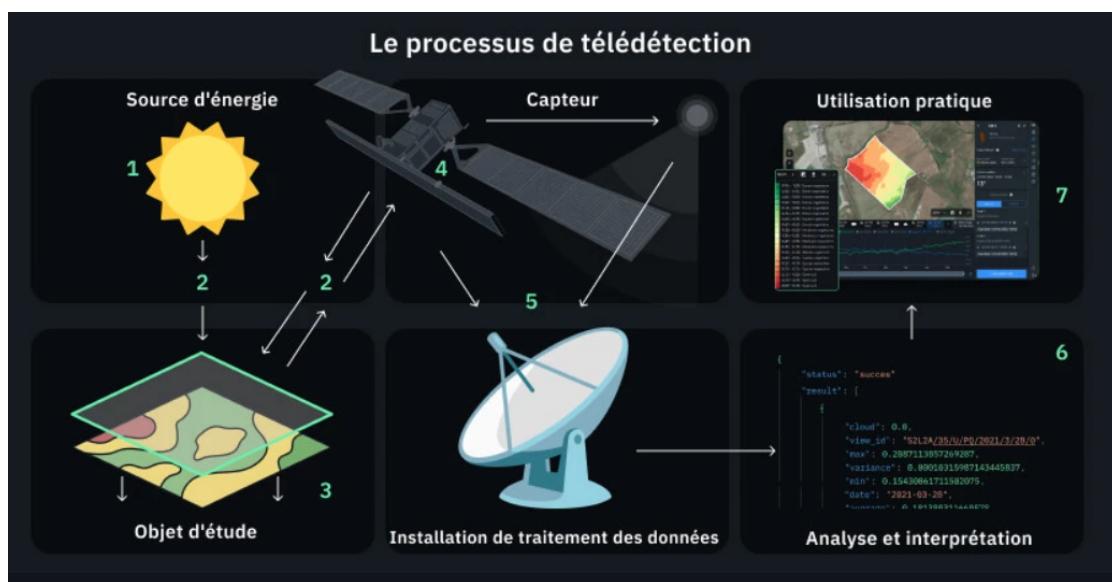


Fig. 3.2 : Le processus de télédétection

Les données OpenSource

Les données OpenSource ont été recueillies au printemps et à l'été 2016. Les images aériennes du Danemark présentent une résolution de 20 cm par pixel, tandis que celles de la Finlande ont une résolution de 50 cm par pixel. Il est important de noter que 90 % des données en très haute résolution (THR) proviennent encore de l'imagerie aérienne.

Les données sur le Danemark proviennent de Styrelsen for Dataforsyning og Infrastruktur (SDFI). SDFI est un organisme danois relevant du ministère du Climat, de l'Énergie et des Services publics. Sa mission consiste à fournir des géodonnées de haute qualité au secteur public et privé, permettant ainsi de prendre des décisions importantes pour la société sur la base des meilleures informations disponibles



Fig. 3.3 : Logo SDFI

Les données finlandaise proviennent de National Land Survey of Finland (NLS), il joue un rôle similaire. Il traite à la fois des questions cartographiques et cadastrales, et gère un système d'information géographique national. De plus, le NLS fournit des services liés à la terre, à l'environnement et aux bâtiments. Le NLS produit également des données géospatiales, notamment des données topographiques



Fig. 3.4 : Logo NLS

Les données TENBS

Les données satellites TENBS ont été prise en février à juillet 2023 avec une résolution de 30cm/px au Congo.

3.2.2 Imagerie par drone

Les drones offrent une résolution spatiale plus élevée que les satellites, permettant de capturer des images détaillées des arbres. Ils sont flexibles et peuvent explorer des zones difficiles d'accès.

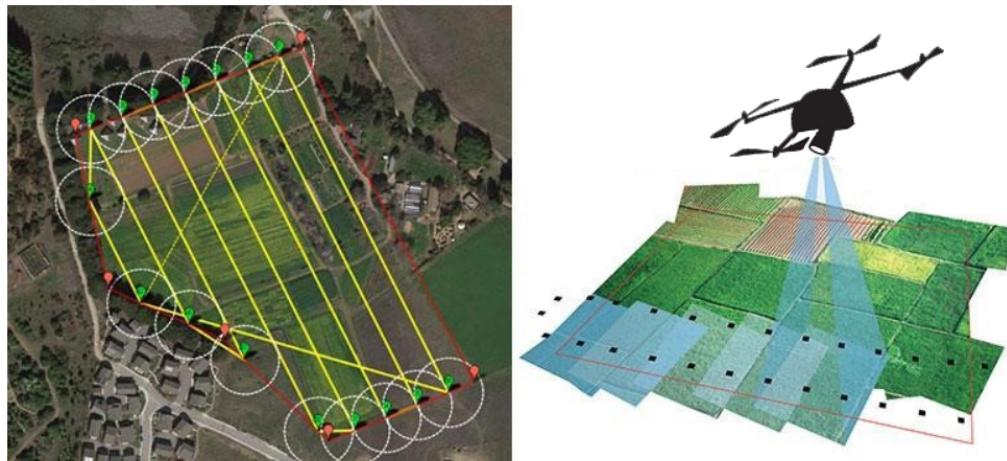


Fig. 3.5 : Schéma d'acquisition de parcelles par drone

Les images drones de TENBS ont été prise en juin 2023 avec une résolution de 3cm/px (10 fois plus de résolution que le satellites). Les données sont acquises par un partenaire du projet.

3.2.3 Outils pour le Labelling

La segmentation d'image est un processus essentiel dans de nombreux systèmes de compréhension visuelle. Elle consiste à attribuer une étiquette à chaque pixel d'une image, de manière que les pixels partageant des caractéristiques similaires soient regroupés.

Dans notre cas, il faut segmenter les couronnes des arbres. Il existe différentes méthodes pour étiqueter nos images :

- De manière manuelle,
- Plugin Geo-SAM : Le plugin Geo-SAM pour QGIS utilise des technologies avancées de deep learning pour améliorer la segmentation des formes de terrain dans les images raster géospatiales. Développé par Meta, le modèle Segment Anything (SAM) repose sur des réseaux de neurones convolutionnels (CNNs) pour identifier et segmenter les objets de manière précise et

rapide. Intégré dans QGIS, Geo-SAM permet aux utilisateurs de charger des images raster, sélectionner des zones d'intérêt, et segmenter interactivement les formes de terrain avec une grande précision. L'interface conviviale facilite l'étiquetage et le traitement des segments, rendant cet outil efficace et accessible même sans expertise approfondie en intelligence artificielle. Grâce à l'apprentissage continu, le modèle SAM s'améliore au fil du temps, offrant des résultats de plus en plus précis pour diverses applications géospatiales.

Le labelling des images satellites TENBS du Congo a été réalisé par un membre interne de la branche OneTech. Cette tâche est très chronophage et a pris 70 heures ; surtout parce que la délimitation des contours des arbres est souvent difficile sur les images satellites. Pour surmonter ce problème, des images prises par des drones, offrant une résolution plus détaillée, ont été utilisées pour mieux identifier et délimiter les contours des arbres et ainsi éviter les faux amis comme certains buissons.

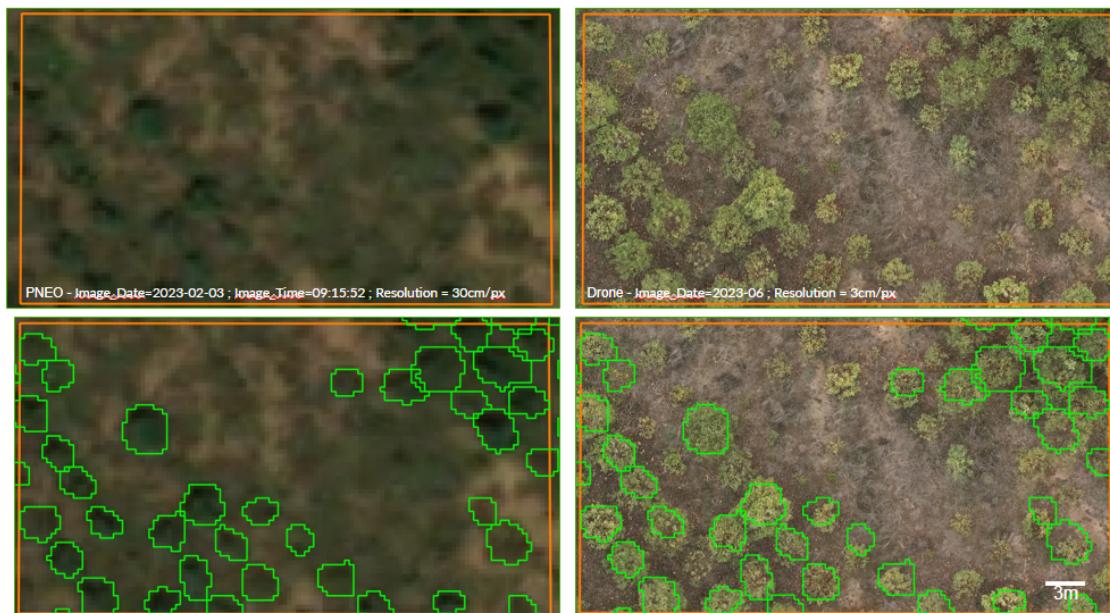


Fig. 3.6 : Images satellites et images drones du projet TENBS

4 Analyse des données

4.1 Inconvénients pour l'acquisition

Les images satellites et des images capturées par des drones présentent des inconvénients spécifiques à prendre en compte. Voici quelques points à considérer :

- **Résolution spatiale :**
 - Les images satellites présentent une résolution spatiale variable selon les capteurs utilisés,
 - Les drones, quant à eux, peuvent fournir des images à **très haute résolution spatiale (THRS)**, permettant de détecter des détails minuscules dans les couronnes d'arbres. Cependant, cela peut entraîner des fichiers volumineux et nécessiter des capacités de stockage et de traitement plus importants.
- **Conditions météorologiques :**
 - Les outils d'acquisition sont soumis aux conditions météorologiques et à la couverture nuageuse. Si le ciel est couvert, les images satellites peuvent être inutilisables. Le vent, la pluie, ombrage, l'angle de vue et d'autres facteurs peuvent affecter la qualité des images.
- **Fréquence d'acquisition :**
 - L'acquisition des images a lieu généralement en fin de matinée et en été afin d'avoir les images optimales pour éviter les mauvaises conditions météorologiques. Cela se fait généralement lorsque le soleil est à son zénith pour éviter les effets d'ombre.
- **Coût :**
 - L'accès aux images peut être coûteux, surtout pour les images à haute résolution.
- **Interprétation des données :**
 - Les images satellites peuvent nécessiter une interprétation plus complexe en raison de la résolution et des conditions d'acquisition.
 - Les images de drones sont plus intuitives, mais l'interprétation reste nécessaire pour identifier correctement les couronnes d'arbres.

4.2 Les données en quelques chiffres

Dans cette section, nous allons examiner les différents jeux de données et analyser plusieurs aspects : le nombre de données de type images, leurs dimensions (hauteur et largeur), ainsi que le nombre d'arbres qu'elles contiennent.

4.2.1 Données du Danemark

- 84 images et 19 645 arbres
- Une moyenne de 1 316 px en largeur
- Une moyenne de 1 139 px en hauteur
- Une moyenne de 200 arbres par image

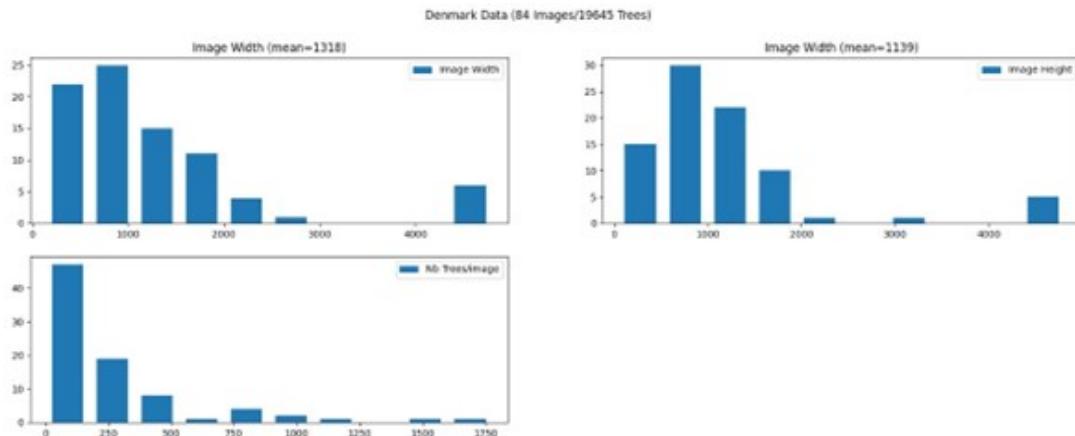


Fig. 4.1 : Donnée du Danemark

4.2.2 Données de la Finlande

- 19 images et 4 773 arbres
- Une moyenne de 425 px en largeur
- Une moyenne de 356 px en hauteur
- Une moyenne de 150 arbres par image

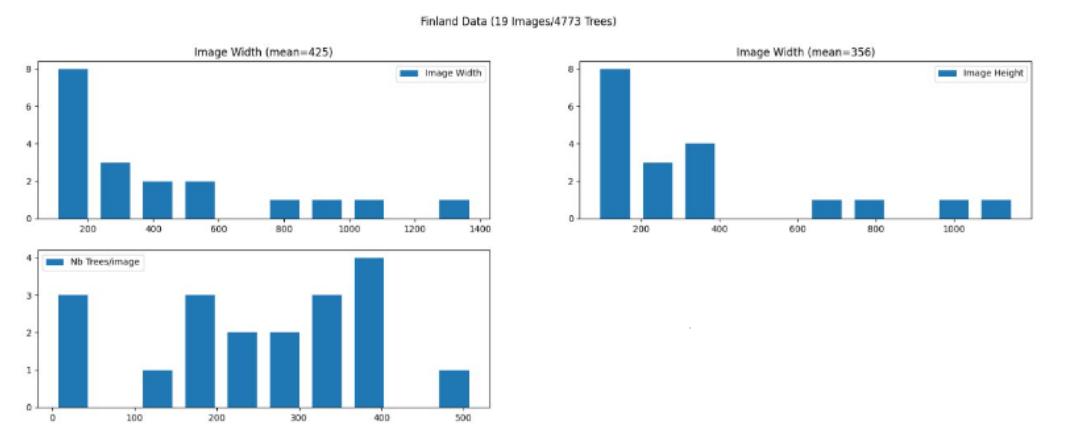


Fig. 4.2 : Donnée de la Finlande

4.2.3 Données de TotalEnergies

- 15 images et 7 797 arbres
- Environ 100k x 100k px en largeur et hauteur

4.3 Format multiple

Les données que nous utilisons proviennent de diverses sources et présentent des différences en termes de contenu, de résolution d'images et de structure.

	Danemark	Finlande	TENBS
Source	SDFI	NLS	TotalEnergies
Nombre d'images	84	19	15
Nombre d'arbres	19 645	4 773	7 297
Taille des images	≈1000 x 1000 px	≈ 400 x 400 px	≈ 100k x 100k px
Acquisition	Aérienne	Aérienne	Satellite/ Drone
Résolution des images	20cm/px	50cm/px	Satellite : 30cm/px Drone : 3cm/px
Date	2016	2016	2023
Pays	Danemark	Finlande	Congo
Images	RVB Masque Carte de densité Hauteurs Infrarouge		

Fig. 4.3 : Données diverses

5 Ingénierie des caractéristiques

5.1 Élimination des données manquantes

Les données qui ne contribuent pas de manière significative au résultat souhaité peuvent être éliminées. Cela est dû à une absence ou insuffisance dans les données. L'élimination des données qui ne peuvent pas être exploité réduit la complexité du modèle et peut améliorer les performances tout en accélérant l'apprentissage. J'ai éliminé des données :

- **Images Drone TENBS** : Ces images ont été utiles pour avoir un labeling précis. En revanche pour le model, TENBS a décidé de baser le modèle sur des images satellites offrant une couverture spatial beaucoup plus large que les drones.
- **Images infrarouge** : Ces images ne sont pas exploitées car en première intention l'accent est mis sur l'identification des arbres à partir d'images en couleur RVB.

5.2 Données à reconstituer

Les données que j'ai reconstituées sont utilisées pour le modèle.

5.2.1 Image RVB

Les images peuvent être stockées soit en format interleaved, où les valeurs des canaux de couleur pour chaque pixel sont regroupées ensemble, soit en format planar, où les valeurs de chaque canal sont stockées séparément dans des plans distincts.

Les images satellites de TENBS sont déjà en couleur stockées en interleaved . En revanche pour les données Opensource sont stockées en planar, les trois images des canaux (rouge, vert et bleu) doivent être combinées pour former une image couleur.

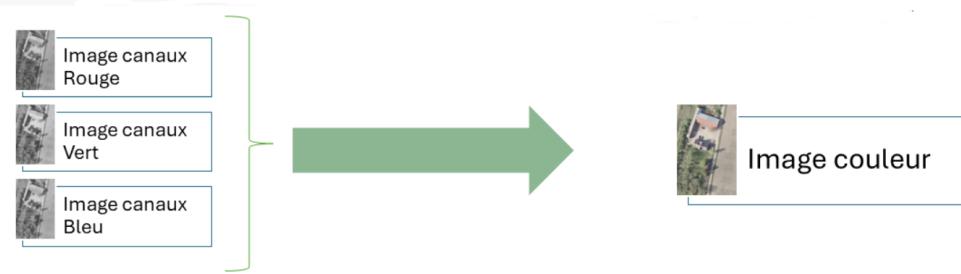


Fig. 5.1 : Création d'une image couleur

Pour créer l'image couleur finale, j'ai fait un programme qui combine ces trois canaux en utilisant le système RVB. Chaque pixel de l'image finale est formé en utilisant les valeurs des trois canaux. Voici la formule générale pour chaque pixel :

$$\text{Pixel final} = (\text{Rouge}, \text{Vert}, \text{Bleu})$$

Par exemple, si un pixel a les valeurs (200, 100, 50) pour les canaux R, V et B respectivement, sa couleur finale sera un mélange de rouge, de vert et de bleu.

5.2.2 Image Masque

Pour créer les images masques pour chaque images RVB, j'utilise un fichier JSON par image qui contient les coordonnées des polygones délimitant les couronnes des arbres. L'image masque résultante est binaire, où le blanc représente l'arbre et le noir est l'arrière-plan

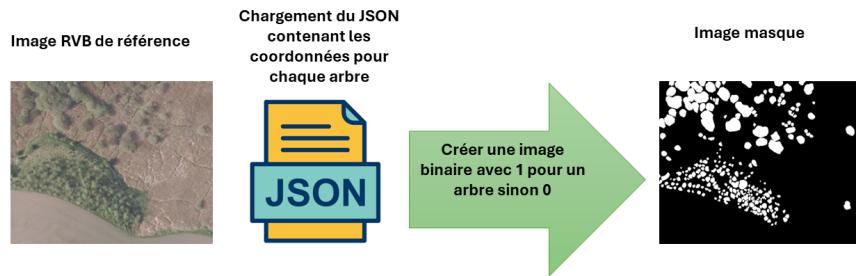


Fig. 5.2 : Crédit d'une image masque

5.2.3 Carte de densité

Pour créer la carte de densité, je charge le fichier JSON des polygones des arbres. À partir de ce fichier, j'ai calculé le centre de chaque arbre. Cette méthode permet de mieux définir les zones où la texture des arbres nous intéresse particulièrement. L'image de la carte de densité sert pour compter le nombre d'arbres sur une image.

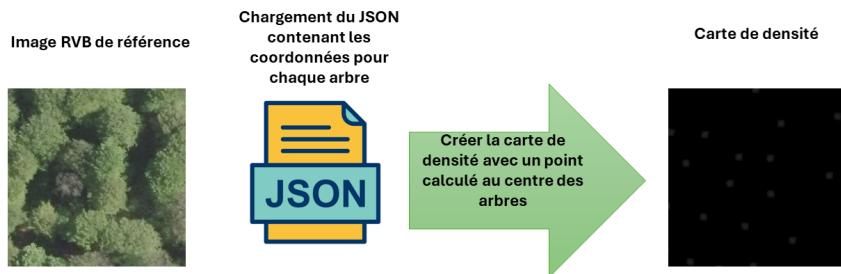


Fig. 5.3 : Crédit d'une carte de densité

6 Augmentation des données

Le jeu de données est faible. Le nombre d'image est insuffisant. Il y a 118 images au total avec des résolutions différentes. Pour palier à ce manque de données des techniques d'augmentation des données devront être réalisées. Telles que : la transformation d'images et la génération d'images synthétiques.

7 Décomposition du problème

Pour pouvoir résoudre le problème, ce dernier a été découpé en sous-problèmes ordonnés dans une séquence logique d'étapes pour les résoudre. Cette décomposition et ordonnancement du problème est une étape essentielle dans la résolution.

Le problème Principal est :

La segmentation et le comptage des arbres à partir d'images satellites

Le principal défi associé aux données est la faible quantité de celles-ci, qui présentent une diversité limitée en termes d'environnements, de pays, d'espèces d'arbres, de résolutions et comportent également des données manquantes. Les données fournies par TotalEnergies sont en nombre restreint et très spécifiques.

L'objectif est de pré-entraîner un modèle sur des jeux de données Opensource. Cela permet à l'algorithme d'apprendre à segmenter un arbre. Ensuite, le modèle est affiné (fine-tuning) avec les données de TENBS. Cette approche devrait rendre le modèle plus robuste.

Pour le produire, la séquence des étapes de résolution suivante va être faite :

1. Collecte
2. Prétraitement des Données : Nettoyage et Transformation
3. Analyse Exploratoire et Visualisation des Données
4. Génération de Données Synthétiques
5. Modélisation et Entraînement : Sélection du Modèle et Division des Données et Entraînement
6. Évaluation et Amélioration

8 Conclusion

La décomposition du problème en sous-problèmes, leur séquencement en étapes logique, l'évaluation continue et l'amélioration sont des éléments clés pour résoudre efficacement des problèmes complexes. Cette approche permet de mieux comprendre le problème, de le traiter de manière plus structurée et d'aboutir à des solutions de qualité.

Chapitre 3

État de l'art : Datascience pour le comptage et la segmentation d'objets dans les images

Sommaire

1	Introduction	46
2	Prétraitement et traitement des données	46
2.1	Techniques de Transformation d'Images	46
2.2	Génération d'Images Synthétiques	46
3	Travaux connexes	47
3.1	Article : Unet	47
3.2	Article : Mask R-CNN	51
3.3	Article : YOLOv5	52
3.4	SAM	54
3.5	Comparaison	54
4	Evaluation des résultats	55
5	Conclusion	57

1 Introduction

La segmentation et le comptage des arbres à partir d'images synthétiques constituent un défi majeur en datascience. Cette tâche complexe nécessite une compréhension approfondie des techniques d'analyse d'images et des algorithmes d'apprentissage automatique.

Dans cette section, nous allons explorer en détail diverses méthodes pour relever ce défi.

2 Prétraitement et traitement des données

Les étapes de prétraitement couramment utilisées sur les données d'images en science des données pour la segmentation d'objets :

2.1 Techniques de Transformation d'Images

Dans le domaine du traitement d'images, diverses techniques sont utilisées pour augmenter la variabilité des données. Parmi elles, on trouve la rotation, le retournement, le recadrage et le changement de luminosité.

La **rotation** consiste à faire pivoter l'image autour de son centre pour obtenir de nouvelles perspectives. Le **retournement** est une autre technique qui crée une image miroir, augmentant ainsi la diversité des données. Le **recadrage** permet de se concentrer sur des parties spécifiques de l'image, ce qui peut aider à mettre en évidence des caractéristiques importantes. Enfin, le **changement de luminosité** modifie l'intensité des couleurs de l'image, ce qui peut aider à améliorer la visibilité des détails.

Ces techniques sont essentielles pour augmenter la variabilité des données, ce qui peut améliorer la robustesse et la performance des modèles d'apprentissage automatique. Elles permettent de créer un ensemble de données plus diversifié et plus représentatif, ce qui est crucial pour la formation de modèles précis et fiables.

2.2 Génération d'Images Synthétiques

En raison d'un manque de données disponibles, j'ai créé des images synthétiques de forêts pour enrichir le jeu de données. Ces images ont été conçues pour présenter une diversité d'arbres et de configurations. J'ai contrôlé l'espacement entre les arbres, créant des scènes plus ou moins compactes, avec des arbres alignés ou dispersés. Cela permet d'avoir une variété d'images pour enrichir le jeu de données.

3 Travaux connexes

L'apprentissage profond a été largement utilisé pour le comptage et la segmentation des arbres. Plusieurs travaux ont été réalisés dans ce domaine, et nous allons en présenter quelques-uns ici.

3.1 Article : Unet

Dans l'article *Deep learning enables image-based tree counting, crown segmentation, and height prediction at national scale, 2023* de Sizhuo Li explore l'utilisation des réseaux de neurones convolutifs Unet pour créer un inventaire national des arbres à partir d'images aériennes.

L'étude a été appliquée à des images couvrant le Danemark et la Finlande, produisant des cartes détaillées du nombre d'arbres, de leur emplacement, de la taille de leur couronne et de leur hauteur dans divers paysages, y compris les forêts denses, les champs ouverts et les zones urbaines.

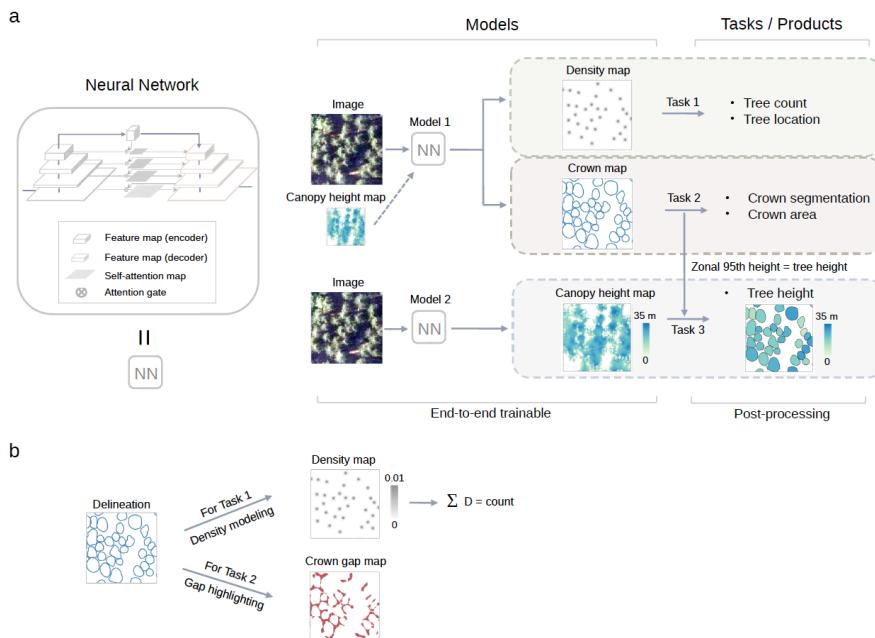


Fig. 3.1 : Modèle Unet de l'article

Il y a deux modèles distincts.

Le premier modèle résout conjointement les tâches de comptage des arbres et de segmentation de la couronne à partir d'images aériennes multibandes et d'une carte de hauteur de la canopée dérivée des données LiDAR. Pour l'approche de segmentation, chaque pixel d'une image est classé comme une couronne d'arbre ou arrière-plan. Une deuxième branche du modèle prédit le nombre d'arbres en utilisant des cartes de densité générées à partir de noyaux gaussiens 2D appliqués sur les délimitations manuelles des couronnes d'arbres.

$$G_{\sigma, m}(\mathbf{p}) = \begin{cases} e^{-\frac{\|\mathbf{p}-\mathbf{m}\|^2}{2\sigma^2}} \cdot \left(\sum_{r,s=-M}^M e^{-\frac{r^2+s^2}{2\sigma^2}} \right)^{-1} & \text{if } m_d - M \leq p_d \leq m_d + M \text{ for } d = 1, 2 \\ 0 & \text{otherwise} \end{cases}$$

$$D(\mathbf{p}) = \sum_{c=1}^C G_{\sigma, \mathbf{m}_c}(\mathbf{p}).$$

Ici $G_{\sigma, m}(\mathbf{p})$ est un noyau gaussien tronqué échantillonné évalué à la position du pixel $\mathbf{p} = (p_1, p_2)^T$ dans l'image. Le noyau est centré autour de $\mathbf{m} = (m_1, m_2)^T$ avec le paramètre de bande passante σ et est tronqué en hauteur/largeur $2M + 1$. $D(\mathbf{p})$ désigne la carte de densité pour les délimitations de l'arbre C centrées à la position $\mathbf{m}_1, \dots, \mathbf{m}_C$ évalué à la position du pixel p .

Fig. 3.2 : Formule pour le comptage d'arbres

Le deuxième modèle utilise des données LiDAR comme données d'entraînement et prédit la hauteur de la canopée à partir d'images aériennes multibandes. Il utilise les hauteurs de canopée estimées et la segmentation de la couronne pour déterminer la hauteur de chaque arbre. Cette hauteur est le 95e centile de la hauteur dans chaque couronne d'arbre prédite.

Model	Band composition	F1-score	Precision	Recall	Mean IoU	Relative bias for counts (%)
M1	RGB + NIR + NDVI + CHM	0.77	0.96	0.69	0.72	10.3
M2	RGB + NIR + NDVI + CHM (prediction)	0.73	0.95	0.64	0.69	21.8
M3	RGB + NIR + NDVI	0.77	0.96	0.69	0.72	-11.5
M4	RGB + NIR	0.76	0.96	0.67	0.71	-12.2
M5	RGB	0.73	0.96	0.64	0.69	17.1
M6	GB + NIR	0.73	0.96	0.64	0.69	-14.4
M7	NIR	0.71	0.95	0.62	0.67	-3.4

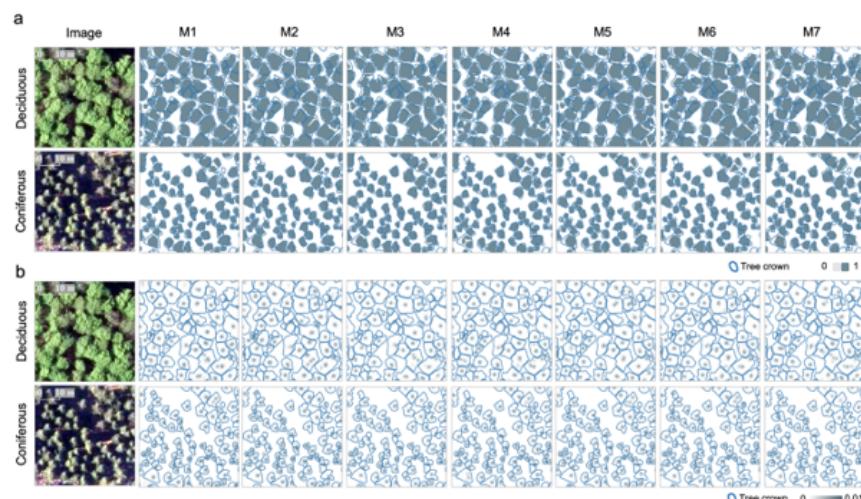


Fig. 3.3 : Résultats du Modèle Unet

Les résultats présentent une analyse de performance de différents modèles (M1 à M7) pour le comptage et la segmentation d'arbres à partir de différentes données en entrées du modèle. Les performances sont évaluées en fonction de plusieurs mesures statistiques, y compris le score F1, la précision, le rappel, le Mean IoU, et le biais relatif pour les comptes.

L'article a prouvé la performance du modèle Unet pour identifier automatiquement des arbres individuels dans divers paysages à partir de différents ensembles de données. Ce modèle peut être adapté à d'autres régions malgré les variations des types de forêts, les caractéristiques des arbres influencées par le climat, les temps d'acquisition des images et les résolutions spatiales.

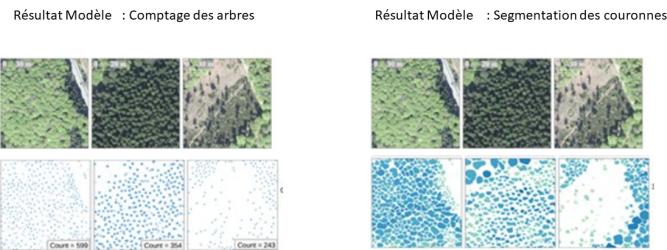


Fig. 3.4 : Résultat de l'article du Modèle Unet

3.2 Article : Mask R-CNN

Dans l'article *Tree Crown Delineation Algorithm Based on a Convolutional Neural Network, 2021* Ricardo Dalagnol présente l'utilisation d'un modèle CNN avancé, le Mask R-CNN, pour la détection des couronnes d'arbres individuelles (TCDD) dans des images satellites RVB à très haute résolution.

L'architecture Mask R-CNN est une structure complexe qui comprend des couches de convolution, des Réseaux de Proposition de Région (RPN) et des Réseaux Entièrement Connectés (FCN). Le Faster R-CNN est responsable de la sélection des propositions de région et est une optimisation du Mask R-CNN. L'ALIGN de la Région d'Intérêt (RoI) standardise toutes les RoI à une forme uniforme. Les FCN sont utilisés pour l'étiquetage de l'objet et la liaison de la boîte. Enfin, les couches de convolution sont utilisées pour déterminer les pixels spécifiques à chaque objet, ce qui est également connu sous le nom de masque d'objet.

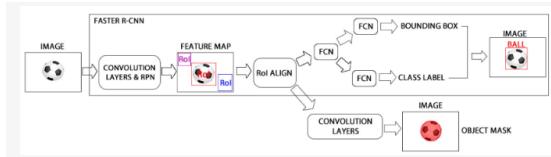


Fig. 3.5 : Modèle Mask R-CNN de l'article

Une méthodologie a été développée pour créer des images forestières simulées pour l'entraînement du modèle CNN. Les principaux avantages de cette méthode sont de faciliter la production d'images d'échantillons d'apprentissage pour les forêts denses et d'obtenir une TCDD individuelle avec une précision sans précédent pour cette forêt tropicale très diversifiée.

Dans cette article, il y a 88% des couronnes d'arbres ont été correctement identifiées. Lorsqu'on regarde de plus près, on trouve que la précision de la détection était de 91%, tandis que le rappel était de 81%. Cela signifie que le modèle a bien fonctionné pour identifier les couronnes d'arbres présentes, mais a parfois manqué certaines d'entre elles. En prenant en compte toutes les couronnes d'arbres que le modèle a détectées, la précision était de 89% et le rappel de 68%. Cela suggère que le modèle a parfois détecté des couronnes d'arbres qui n'étaient pas réellement présentes dans les images.

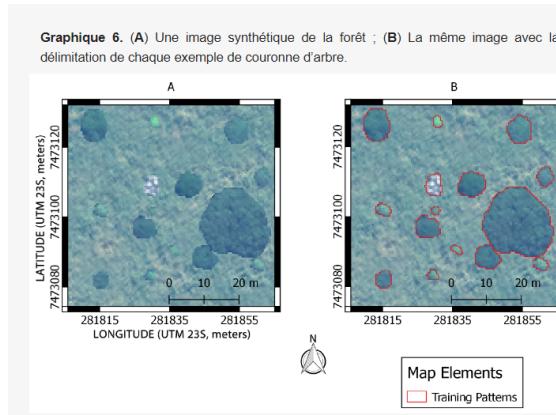


Fig. 3.6 : Forêt synthétique de l'article

Métrique	Valeur moyenne (toutes les cimes d'arbres détectées)	Valeur moyenne ($\text{IoU} \geq 0.5$)
Recall	0.68	0.81
Precision	0.89	0.91
F_1 score	0.77	0.86

Fig. 3.7 : Résultats des mesures d'évaluation pour toutes les couronnes d'arbres détectées par Mask R-CNN

3.3 Article : YOLOv5

Dans l'article *Tree Seedlings Detection and Counting Using a Deep Learning Algorithm, 2023* on trouve le réseau de détection d'objets YOLOv5 pour détecter et compter trois types de semis d'arbres. Le modèle a été formé sur 7000 images et validé sur 2000 images.

Elle utilise un réseau de détection d'objets YOLOv5, formé sur trois types de semis d'arbres : l'épinette dragon, l'aronia noir et le pin sylvestre. Les données ont été augmentées pour améliorer la précision du modèle et éviter le surajustement.

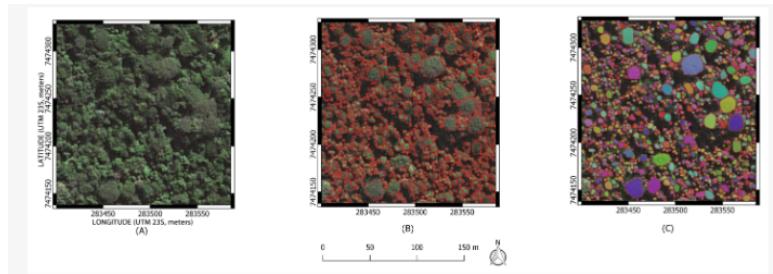


Fig. 3.8 : Résultat de la segmentation du Mask R-CNN

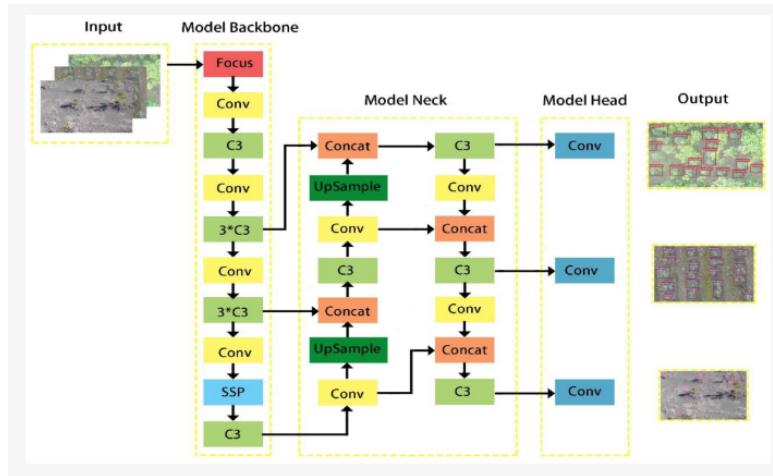


Fig. 3.9 : Modèle de YOLOv5

Les résultats montrent que la méthode peut identifier et compter efficacement les semis d'arbres dans une image, avec une précision moyenne de 95,10%

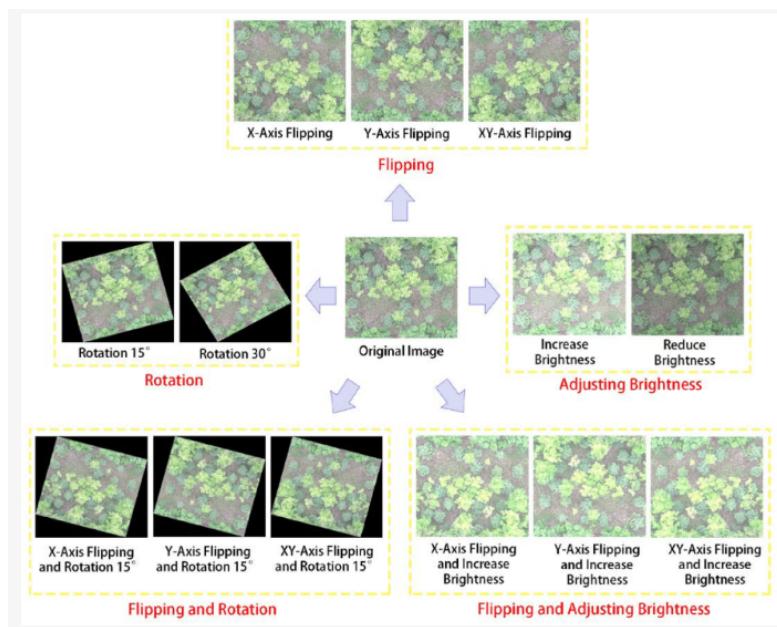


Fig. 3.10 : Exemples d'augmentation des données de l'article Yolov5

Planter	PQ	FN	FP	P (%)	R (%)	F1_Score (%)	Précision (%)	carte
Épinette dragon	485	4	3	99.18	99.18	99.28	98.58	89.87%
Aronia noir	1050	60	36	96.69	94.59	95.63	91.62	89.19%
Pin sylvestre	350	8	10	97.22	97.77	97.49	95.11	95.68%

Fig. 3.11 : Résultat de l'article du Modèle YOLOv5

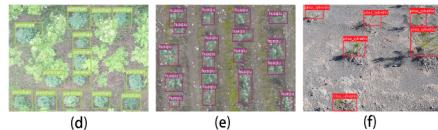


Fig. 3.12 : Résultat de l'article du Modèle YOLOv5

Mask R-CNN, YOLOv5 et U-Net sont trois modèles populaires utilisés dans la vision par ordinateur. Chacun d'eux a ses propres spécificités et applications, notamment dans l'analyse des forêts.

3.4 SAM

Modèle SAM (Segment Anything Model) de Meta : C'est un modèle pré-entraîné conçu pour être adapté à des tâches spécifiques grâce au "fine tuning". Il peut être ré-entraîné et utilisé pour segmenter des objets dans un ensemble de données

3.5 Comparaison

En comparaison, U-Net est particulièrement adapté pour la segmentation séquentielle où chaque pixel de l'image est classifié. Son principal avantage est sa légèreté et sa capacité à fonctionner comme un réseau multi-tâches, ce qui n'est pas possible avec Mask R-CNN.

Mask R-CNN est utile pour la segmentation de chaque objet détecté, mais il présente des limitations significatives en raison du Réseau de Propositions de Régions (RPN). SAM peut améliorer la robustesse et la performance des modèles de vision par ordinateur, mais sa complexité le rend excessif et difficile à maîtriser, ce qui est problématique dans un domaine industriel. Les modèles YOLO, bien qu'extrêmement rapides et précis, partagent les mêmes limitations que Mask R-CNN et nécessitent des ajustements pour des tâches spécifiques où la vitesse de détection est cruciale.

4 Evaluation des résultats

Pour la segmentation et le comptage d'objets dans les images, plusieurs métriques et fonctions de perte peuvent être utilisées. Voici quelques-unes d'entre elles :

Fonctions de perte :

- MSE(Mean Squared Error) : C'est une fonction de perte utilisée pour mesurer l'erreur entre les valeurs prédites par le modèle et les valeurs réelles. Elle calcule la moyenne des carrés des différences entre les valeurs prédites et réelles. Plus la valeur de MSE est faible, meilleure est la précision du modèle.
- Binary_crossentropy : C'est une fonction de perte utilisée pour les tâches de classification binaire. Elle mesure la dissimilarité entre les distributions de

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

MSE = mean squared error
 n = number of data points
 Y_i = observed values
 \hat{Y}_i = predicted values

Fig. 4.1 : Formule MSE

probabilité des étiquettes vraies et des étiquettes prédites. Plus la valeur de la binary crossentropy est faible, plus la prédiction est précise. Cette métrique est souvent utilisée pour les tâches de segmentation binaire, où le modèle doit prédire si chaque pixel appartient à un objet ou à l'arrière-plan.

$$L_{BCE} = -\frac{1}{n} \sum_{i=1}^n (Y_i \cdot \log \hat{Y}_i + (1 - Y_i) \cdot \log (1 - \hat{Y}_i))$$

Fig. 4.2 : Formule binary crossentropy

- Tversky Loss : C'est une autre fonction de perte pour la segmentation d'images. Elle est basée sur l'indice de Tversky, qui est une mesure de la similarité entre deux ensembles qui peut être ajustée pour donner plus ou moins de poids aux faux positifs par rapport aux faux négatifs.

$$\text{Tversky Index} = \frac{|A \cap B|}{|A \cap B| + \alpha|A \setminus B| + \beta|B \setminus A|} \quad (3.1)$$

$$\text{Tversky Loss} = 1 - \text{Tversky Index} \quad (3.2)$$

où A est le masque de vérité terrain, B est le masque prédit, et α et β sont des paramètres qui contrôlent les poids des faux négatifs et des faux positifs respectivement.

Métriques :

- RMSE (Root Mean Squared Error) : C'est une mesure utilisée pour évaluer la performance d'un modèle. Il représente la racine carrée de la moyenne des

erreurs au carré entre les valeurs prédites par le modèle et les valeurs réelles observées.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.3)$$

où y_i est la valeur observée, \hat{y}_i est la valeur prédite, et n est le nombre d'observations.

- IoU (Intersection sur Union) : C'est le rapport entre l'intersection et l'union de la zone prédite et de la zone réelle. Il est souvent utilisé pour mesurer la précision de la segmentation d'objets.

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (3.4)$$

où A est le masque de vérité terrain et B est le masque prédit. $|A \cap B|$ est la zone d'intersection entre les deux masques et $|A \cup B|$ est la zone de leur union.

- Dice Loss : Elle est basée sur le coefficient de Dice, qui est une mesure de la similarité entre deux ensembles.

$$\text{Dice Coefficient} = \frac{2|A \cap B|}{|A| + |B|} \quad (3.5)$$

où A est le masque de vérité terrain et B est le masque prédit. $|A \cap B|$ est l'intersection des deux masques, $|A|$ et $|B|$ sont les tailles des masques.

La Dice Loss est alors :

$$\text{Dice Loss} = 1 - \text{Dice Coefficient} \quad (3.6)$$

5 Conclusion

Comme nous l'avons vu, plusieurs algorithmes existent pour le comptage d'arbre. Ils ont été obtenus à partir de riches jeux de données. La data augmentation est vitale pour l'obtention d'un bon modèle. Les techniques de transformations d'images et la génération d'images synthétiques vont être appliquées pour augmenter la variabilité des données et ainsi aider le modèle à mieux généraliser. Unet est plus adaptées grâce à sa performances en terme de rapidité d'exécution et facilité de mise en œuvre.

Deuxième partie

Système réalisé

Table des matières

4	Implémentation du système	63
1	Introduction	65
2	Collecte et Reconstitution des données	66
3	Prétraitement	67
4	Générations d'images synthétiques	71
5	Séparation des données	76
6	Algorithme de segmentation et comptage : Unet	77
7	Évaluation du modèle	79
8	Conclusion	80
5	Expérimentations et résultats	81
1	Introduction	82
2	Sélection de la méthode de prétraitements	82
3	Résultats obtenus	83
4	Déduction globales	89
6	Conclusion	91
	Conclusion	91
	Glossaire	93
	Table des figures	95

Table des matières	99
---------------------------	-----------

Chapitre 4

Implémentation du système

Sommaire

1	Introduction	65
2	Collecte et Reconstitution des données	66
2.1	Visualisation des données	66
2.2	Reconstitution des données	66
3	Prétraitement	67
3.1	Normalisation	67
3.2	Calcul de la carte de densité	68
3.3	Traitements des données	69
4	Générations d'images synthétiques	71
4.1	Initialisation	73
4.2	Sélection des images de référence	73
4.3	Positionnement	74
4.4	Création de Masques et Densités pour Arbres Positionnés	74
4.5	Data-augmentation	74
4.6	Combinaison	74
4.7	Résultats	75
5	Séparation des données	76
6	Algorithme de segmentation et comptage : Unet	77
6.1	Structure du Modèle	77
7	Évaluation du modèle	79
7.1	Prédiction de Densité :	79

7.2	Segmentation des Polygones :	79
7.3	Comptage :	80
8	Conclusion	80

1 Introduction

Le système que j'ai réalisé comporte les étapes suivantes :

- Collecte et Reconstitution des données,
- Prétraitement / Traitements des données,
- Générations d'images synthétiques,
- Séparation des données,
- Réseau de neurone convolutif pour la segmentation et comptage,
- Évaluation du modèle.

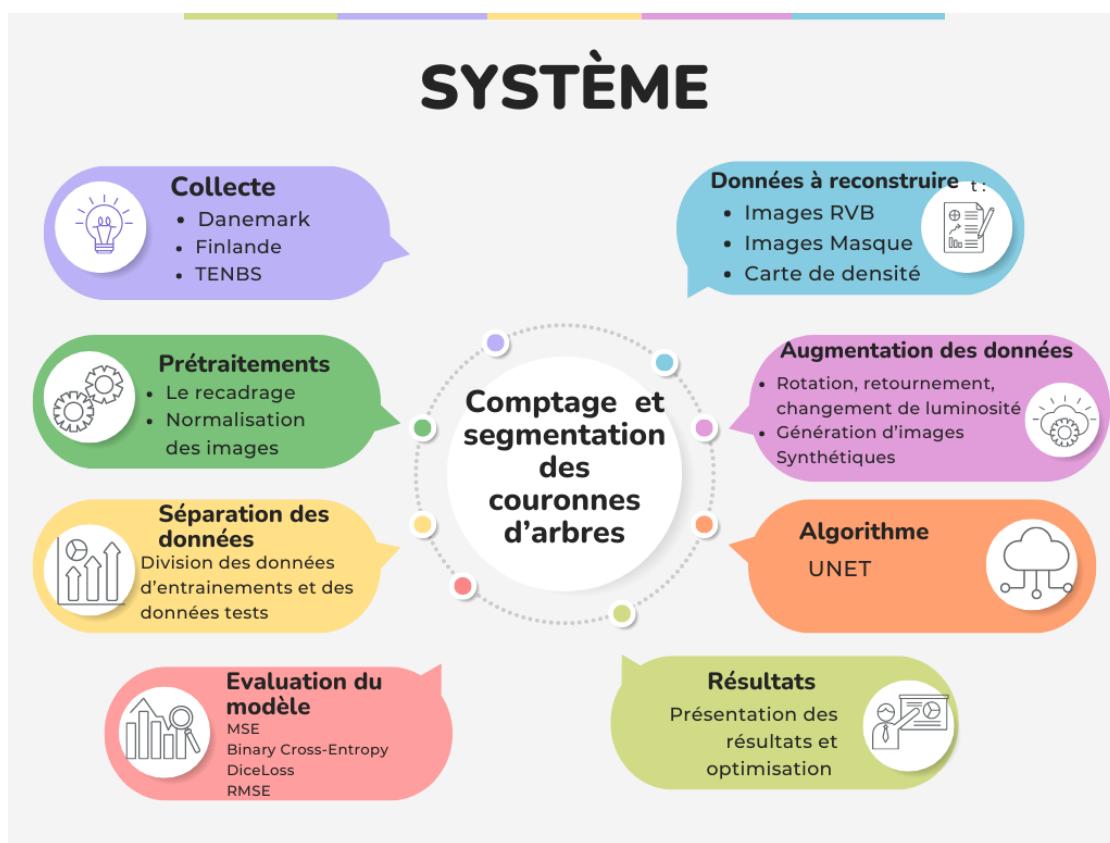


Fig. 1.1 : Etapes du système réalisé

2 Collecte et Reconstitution des données

Les images que nous avons proviennent de deux sources distinctes : Opensource et TENBS. Les images Opensource ont été acquises au Danemark et Finlande, tandis que celles de TENBS proviennent du Congo. Ces images présentent une variété de résolutions, de paysages et de dates d'acquisition. Voici quelques exemples de ces images :

2.1 Visualisation des données

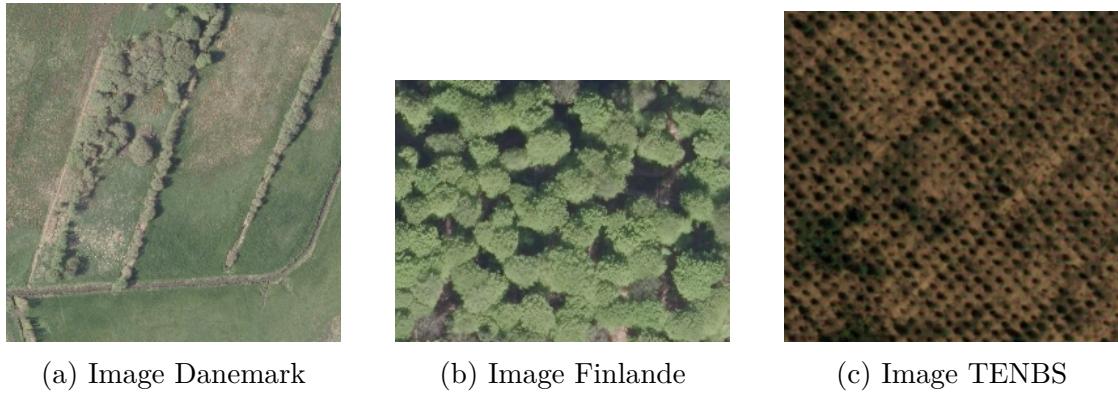


Fig. 2.1 : Visualisation des données

Les images ci-dessus mettent en évidence la diversité des paysages, ainsi que les différentes résolutions utilisées pour les capturer, soulignant ainsi le défi pour la segmentation des arbres.

2.2 Reconstitution des données

Pour mon projet, j'ai créé de nouvelles données à partir des images récupérées. Une image couleur est recomposée à partir des fichiers RVB. Elle est utilisée comme entrée pour le modèle. En sortie, le modèle génère deux types de données : une carte de densité qui identifie chaque arbre par un point central, et une image masque binaire où les arbres sont représentés en blanc sur un fond noir. Ces sorties permettent une analyse détaillée de la distribution et des contours des arbres.

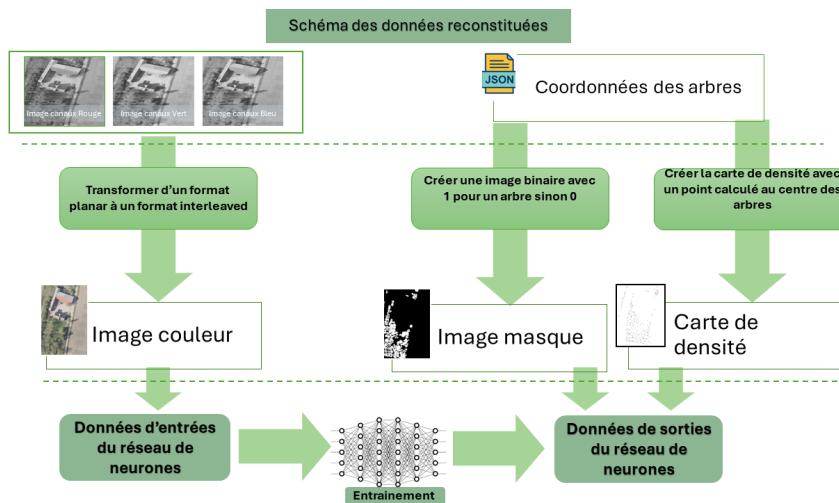


Fig. 2.2 : Schéma de reconstitution des données

3 Prétraitement

3.1 Normalisation

Pour le projet, j'ai procédé à la normalisation des images RVB et de la carte de densité. En revanche, je n'ai pas appliqué cette normalisation à l'image masque binaire, car elle contient des valeurs discrètes (0 et 1) représentant des catégories distinctes, telles que l'arrière-plan et les arbres, qui ne nécessitent pas d'ajustement d'échelle.

La normalisation des données ajuste les valeurs pour qu'elles soient comprises entre [0, 1].

Fonctionnement de la Normalisation des Images

- On identifie les valeurs minimales et maximales des pixels.
- Chaque pixel est ajusté par :

$$\text{pixel_normalisé} = \frac{\text{pixel} - \text{min}}{\text{max} - \text{min}}$$

Fig. 3.1 : Formule de normalisation

Avantages

- Uniformité : Facilite la comparaison entre différentes images.
- Stabilité Numérique : Améliore la convergence et la stabilité des modèles.
- Performance : Accélère l'entraînement et améliore les résultats des modèles.
- Prévention des Saturations : Évite que certaines valeurs dominent les autres.

3.2 Calcul de la carte de densité

L'intégration d'une carte de densité dans les modèles U-Net pour la segmentation d'objets améliore la précision et la robustesse de la segmentation. Elle fournit des informations supplémentaires sur la position et la densité des objets, aide à réduire les faux positifs et améliore la capacité du modèle à segmenter des objets chevauchants ou dans des environnements variés.

Pour la carte de densité, j'ai choisi de tester deux méthodes de calcul.

3.2.1 Méthode 1 : Noyau Gaussien

Fonctionnement :

- Pour chaque d'arbre, une distribution gaussienne est appliquée. Cette distribution a une forme de tache centrée sur le point d'intérêt.
- La formule de la distribution gaussienne en 2D est :

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{(x - \mu_x)^2 + (y - \mu_y)^2}{2\sigma^2}\right)$$

Fig. 3.2 : Gausienne

Indication : μ_x et μ_y sont les coordonnées du point d'intérêt, et σ est l'écart type qui contrôle la largeur de la tache.

- Les distributions gaussiennes générées pour chaque point d'intérêt sont superposées pour former la carte de densité finale.

Avantages :

- Produit une carte de densité floue et continue.
- Idéal pour visualiser des distributions étendues.

3.2.2 Méthode 2 : Transformée de Distance Euclidienne

Fonctionnement

- Utilise un masque binaire où les pixels d'intérêt sont marqués.
- Calcule la distance de chaque pixel au pixel d'intérêt le plus proche. La distance euclidienne entre deux points (x_1,y_1) et (x_2,y_2) est donnée par :

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Fig. 3.3 : Euclidienne

Avantages :

- Simple et rapide à implémenter.
- Fournit des mesures de distance précises.

3.2.3 Comparaison

- **Noyau Gaussien** : Idéal pour des visualisations floues et continues, mais plus complexe à calculer.
- **Distance Euclidienne** : Idéal pour des mesures de distance précises, mais ne produit pas de densité floue.

3.3 Traitements des données

Pour traiter mes données d'image, j'ai effectué plusieurs étapes afin d'assurer la cohérence et la qualité des entrées pour l'analyse.

Redimensionnement des Images :

- Mes images d'origine n'avaient pas toutes la même taille. Pour uniformiser leur dimension, j'ai redimensionné toutes les images en utilisant une méthode de découpage en tuiles.
- Chaque tuile a été redimensionnée à 256x256 pixels. Cela offre un bon compromis entre détails suffisants et complexité calculatoire gérable. C'est compatible avec de nombreuses architectures de réseaux neuronaux populaires.

Enfin cela permet un entraînement efficace des modèles tout en conservant la performance.

Découpage en Tuiles :

- J'ai découpé les images en zones aléatoires pour créer les tuiles. Cette technique permet de conserver une diversité de contenu tout en standardisant la taille des images.
- Les tuiles ont été extraites, puis certaines ont été retournées pour augmenter la variabilité des données.

Application aux Différents Types d'Images : Les images RVB, les masques binaires et la carte de densité ont été uniformément redimensionnés et découpés pour assurer leur correspondance mutuelle.

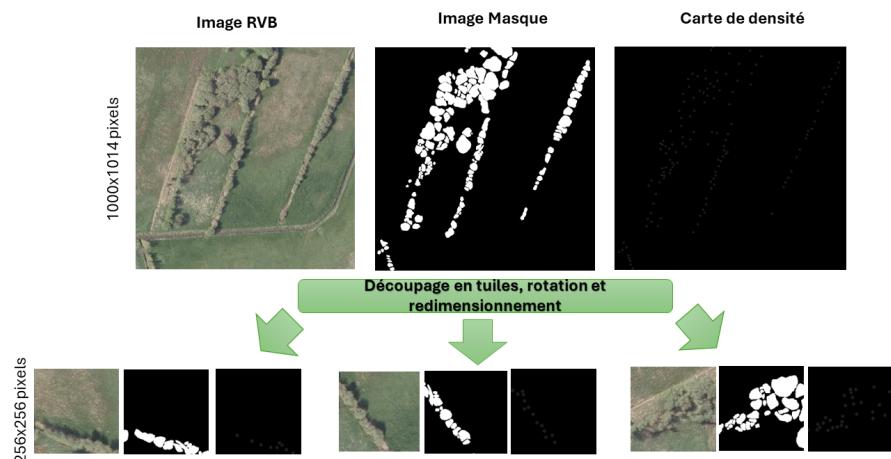


Fig. 3.4 : Schéma de l'augmentation de données par tuiles

Ces techniques ont permis d'augmenter le jeu de données de 118 images à **3 304** images.

	Opensource	TENBS
Nombre d'images	103	15
Nombre d'images Après tuilages	2 254	750

Fig. 3.5 : Augmentation des données

En somme, la technique de tuilage d'images apporte des avantages significatifs en termes d'augmentation de données, d'utilisation efficace des ressources de calcul, d'amélioration de la performance du modèle, de gestion des grandes images, et de diversification des données.

4 Générations d'images synthétiques

Dans cette section, je vais expliquer comment j'ai programmé la génération d'images synthétiques. L'objectif principal est de créer une forêt aléatoire composée d'une diversité d'arbres. Pour ce faire, j'ai développé un algorithme itératif qui permet de varier les types d'arbres, leurs couleurs, ainsi que leur répartition spatiale dans l'image. J'ai également intégré des techniques de rendu réaliste pour améliorer l'apparence visuelle des arbres, en tenant compte de facteurs tels que l'éclairage et les ombres. Le résultat est une série d'images synthétiques de forêts, chacune unique, qui vont être utilisées pour l'entraînement du modèles.

Les étapes de la génération d'images synthétiques

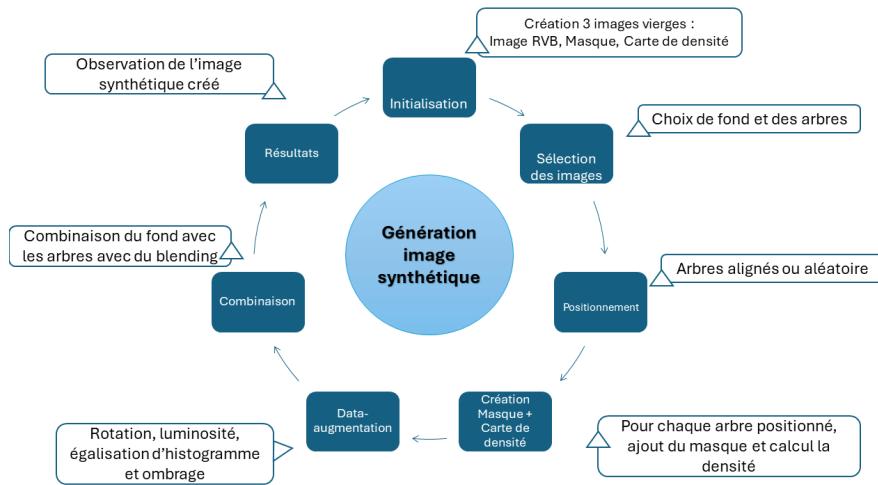


Fig. 4.1 : Les étapes de la génération d'images synthétiques

4.1 Initialisation

Cette étape d'initialisation consiste à créer trois images vierges dans lesquelles les arbres, les masques et la carte de densité seront insérés.

4.2 Sélection des images de référence

En utilisant des images Opensource et de TENBS, j'ai sélectionné plusieurs images dépourvues d'arbres pour pouvoir en ajouter de nouveau. Ces images m'ont servi de fond.

Ensuite, j'ai développé un programme pour découper un ensemble d'arbres de mon jeu de données que j'ai archivé. Ces arbres seront ajoutés au fond précédemment choisi.



Fig. 4.2 : Exemple d'arrière-plan pour image synthétiques 1



Fig. 4.3 : Exemple d'arrière-plan pour image synthétiques 2

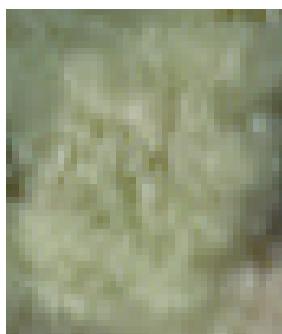


Fig. 4.4 : Exemple d'arbre pour image synthétiques

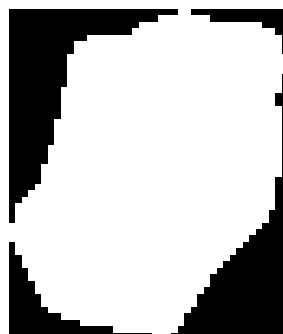


Fig. 4.5 : Image du masque associé à l'arbre

4.3 Positionnement

Pour obtenir une diversité dans les forêts, j'ai ajusté la position des arbres. Cela m'a permis d'avoir des arbres alignés ou disposés de manière aléatoire, avec des espacements variables.

4.4 Création de Masques et Densités pour Arbres Positionnés

Chaque fois qu'un arbre a été sélectionné et positionné sur l'image, j'ai généré son masque correspondant et calculé sa carte de densité.

4.5 Data-augmentation

J'ai apporté des légères modifications à l'arrière-plan et aux arbres en effectuant des **rotations**, en ajustant la **luminosité**, en égalisant les histogrammes des arbres ajoutés, et en appliquant des **effets de miroir**. Pour l'**ombrage**, j'ai pris le masque que j'ai légèrement décalé selon un certain angle, puis j'ai ajouté l'ombrage sur l'arrière-plan en le fonçant. Ces changements m'ont permis d'augmenter la variété d'arbres.

4.6 Combinaison

J'ai combiné l'images arrière-plan et les arbres de manière à ce qu'elles se fondent l'une dans l'autre, créant ainsi une image composite et naturelle.

Le blending entre les objets et les masques est une technique utilisée dans la composition d'images synthétiques. Voici comment cette technique est développée :

- **Images sources** : On a deux images sources : l'image de fond et les arbres à superposer. L'image à superposer est accompagnée d'un masque. Ce masque détermine les zones où l'image à superposer sera visible et celles où elle sera transparente.
- **Alpha Blending** : Pour chaque pixel de l'image à superposer, on combine sa couleur avec celle de l'image de fond en utilisant la formule suivante :

En appliquant cette opération pour chaque pixel des deux images, on obtient une nouvelle image composite, où l'objet est intégré de manière réaliste dans l'image de fond.

$$I_{\text{blended}}(x, y) = \alpha \cdot I(x, y) + (1 - \alpha) \cdot M(x, y)$$

où :

- $I_{\text{blended}}(x, y)$ est la valeur du pixel à la position (x, y) dans l'image résultante après le blending.
- $I(x, y)$ est la valeur du pixel à la position (x, y) dans l'image originale.
- $M(x, y)$ est la valeur du pixel à la position (x, y) dans le masque.
- α est le facteur de blending entre 0 et 1.

Fig. 4.6 : Formule alpha blending

4.7 Résultats

Pour chaque image synthétique, j'ai généré trois types d'images : l'image RVB, son masque et sa carte de densité. Voici les résultats de mes images synthétiques.



Fig. 4.7 : Image d'arrière-plan



Fig. 4.8 : Image synthétique



Fig. 4.9 : Image d'arrière-plan



Fig. 4.10 : Image synthétique



Fig. 4.11 : Image d'arrière-plan



Fig. 4.12 : Image synthétique

	Opensource	TENBS
Nombre d'images	103	15
Nombre d'images synthétiques	1 451	3 300

Fig. 4.13 : Augmentation des données avec images synthétiques

J'ai considérablement enrichi le jeu de données en y ajoutant des données synthétiques. Ces données synthétiques, conçues pour être proches de la réalité terrain, visent à améliorer la capacité du modèle à généraliser à identifier les arbres dans divers contexte.

5 Séparation des données

Pour développer efficacement mon modèle, j'ai divisé mes données en trois ensembles distincts :

Les données d'entraînement représentent environ 70% du total. Elles sont utilisées pour enseigner au modèle à reconnaître les motifs et les caractéristiques des images, afin qu'il puisse généraliser correctement.

Les données de validation constituent environ 15% du jeu de données. Elles servent à évaluer la performance du modèle pendant l'entraînement, permettant ainsi de ajuster les paramètres du modèle et d'éviter le surapprentissage.

Les données de test, également à hauteur d'environ 15%, sont réservées pour évaluer la performance finale du modèle après son entraînement. Elles offrent une mesure objective de la capacité du modèle à généraliser sur de nouvelles données qu'il n'a pas encore vues.

J'ai créé plusieurs ensembles de données comprenant des données open source, des données TENBS et des données synthétiques. J'ai ensuite évalué plusieurs modèles en utilisant ces ensembles de données et testé deux méthodes de normalisation : la normalisation gaussienne et la normalisation euclidienne.

6 Algorithme de segmentation et comptage : Unet

Pour mon système, j'ai choisi d'utiliser le réseau Unet comme architecture principale en raison de sa capacité à effectuer efficacement la segmentation sémantique d'images. Ce modèle est spécialement conçu pour les tâches de prédiction de densité et de segmentation d'arbres dans les images.

6.1 Structure du Modèle

6.1.1 Entrée

- Le modèle prend en entrée des images de taille spécifiée 256x256 pixels.

6.1.2 Encoder : Blocs de Convolution et Pooling

- L'encodeur est constitué de quatre blocs, chacun comportant deux couches de convolution suivies d'une couche de pooling.
- Les filtres de convolution augmentent progressivement en nombre (16, 32, 64, 128), permettant d'extraire des caractéristiques à différentes échelles.
- Chaque couche de convolution utilise l'activation ReLU, l'initialisation des poids he_normal, et un padding 'same'.

6.1.3 Bloc Bottleneck

- Le bottleneck est une couche intermédiaire qui applique deux convolutions successives avec 256 filtres.
- Cela permet de capturer les caractéristiques les plus profondes de l'image avant le processus de décodeur.

6.1.4 Decoder : Blocs de Transpose Convolution et Concaténation

- Le décodeur utilise quatre blocs de convolution transposée pour augmenter la résolution des caractéristiques.
- Chaque bloc de convolution transposée est suivi d'une concaténation avec les sorties correspondantes de l'encodeur, réintégrant les informations contextuelles des couches de résolution inférieure.
- Le nombre de filtres diminue progressivement (128, 64, 32, 16) dans les blocs de convolution du décodeur.

6.1.5 Sorties

- Carte de Densité : Une couche de convolution 2D avec un filtre de taille 1x1 et une activation linéaire (density_output).
- Masque de Segmentation : Une couche de convolution 2D avec un filtre de taille 1x1 et une activation sigmoïde (polygons_output).

6.1.6 Optimiseur Adam Personnalisé

- J'ai utilisé l'optimiseur Adam avec des paramètres personnalisés pour améliorer la convergence et la performance du modèle.
- Les paramètres de l'optimiseur Adam ont été ajustés comme suit :
 - Taux d'apprentissage (learning rate) : 0.001
 - β_1 : 0.9
 - β_2 : 0.999
 - Épsilon : $1e^{-8}$

6.1.7 Batch Size et Époques

- Taille de batch (batch size) : 16
- Nombre d'époques (epochs) : 20

Les réseaux de neurones, bien que puissants, sont souvent difficiles à contrôler et à ajuster. C'est pourquoi j'ai exploré plusieurs modèles et testé deux méthodes de normalisation, la normalisation gaussienne et la normalisation euclidienne, pour optimiser la performance du Unet dans ce contexte.

7 Évaluation du modèle

Pour la segmentation et le comptage d'objets dans les images, j'ai utilisé les métriques et fonctions de perte suivantes :

7.1 Prédiction de Densité :

- **Fonction de perte** : Utilisation de `MSE` (Mean Squared Error), adaptée à la prédiction de densités. Cette fonction vise à minimiser l'écart quadratique moyen entre les valeurs prédites et les valeurs réelles de densité, assurant une précision numérique élevée dans la représentation des densités d'objets.
- **Métrique** : Utilisation de `RootMeanSquaredError` (RMSE), une métrique qui mesure l'écart moyen entre les valeurs prédites et réelles de densité. Cette métrique fournit une évaluation directe de la précision numérique du modèle dans la prédiction des densités d'objets.

7.2 Segmentation des Polygones :

- **Fonction de perte** : Utilisation de `binary_crossentropy`, optimale pour la classification binaire comme la segmentation des polygones. Cette fonction vise à minimiser la divergence entre les distributions prédites et réelles des polygones, facilitant une segmentation claire et précise des contours d'objets.
- **Métrique** : Utilisation de `DiceLoss`, une métrique efficace pour évaluer la similarité entre les zones segmentées par le modèle et les zones réelles de polygones. Cette métrique fournit une mesure précise de la qualité de la segmentation des contours d'objets.

7.3 Comptage :

Le comptage des arbres se fait en deux étapes principales.

D'abord, on étiquette et compte les arbres dans le masque de référence pour obtenir le nombre d'arbres réels. Ensuite, on transforme le masque et la carte de densité prédicts en deux images binaires avec un seuil de 0,8, puis on compte les arbres dans cette image binaire.

Ensuite, on compare ces nombres d'arbres prédicts avec ceux de référence pour chaque image. Le pourcentage de bonnes classifications est calculé en divisant le nombre de prédictions correctes par le nombre total de comparaisons.

En résumé, on compte les arbres dans les masques de référence et de prédiction, puis on évalue la précision des prédictions en comparant ces comptages.

8 Conclusion

En conclusion, le prétraitement des données est essentiel pour garantir la qualité des données et améliorer la performance des modèles. J'ai appliqué des techniques data-augmentation et génération d'image synthétique pour enrichir mon ensemble de données d'apprentissage. Les données ont été divisées en ensembles d'entraînement, de validation et de test pour évaluer les modèles. L'algorithme Unet a été utilisés pour le comptage et la segmentation des arbres. L'évaluation s'est basée pour :

Prédiction de densité

- Fonction de perte : MSE (Mean Squared Error)
- Métrique : RootMeanSquaredError (RMSE)

Segmentation des Polygones :

- Fonction de perte : binary_crossentropy
- Métrique : DiceLoss

Chapitre 5

Expérimentations et résultats

Sommaire

1	Introduction	82
2	Sélection de la méthode de prétraitements	82
2.1	Résultats obtenus : Méthode gaussienne	82
2.2	Résultats obtenus : Méthode euclidienne	82
2.3	Comparaison sur les prétraitements	83
3	Résultats obtenus	83
3.1	Données Opensource	84
3.2	Données TENBS	85
3.3	Données synthétiques	87
4	Déduction globales	89

1 Introduction

Dans cette section, je présente les résultats obtenus avec le modèle Unet. Nous examinerons les résultats pour différents prétraitements, notamment le calcul de la carte de densité à l'aide des méthodes gaussienne et euclidienne. Nous analyserons les performances du premier modèle avec des données Opensource, ainsi que les résultats avec les données de TENBS et des données générées de manière synthétique.

2 Sélection de la méthode de prétraitements

Dans les visualisations suivantes, j'ai inclus l'image RVB de référence avec les prédictions du modèle pour le masque et la carte de densité, ainsi que les masques et cartes de densité attendus.

2.1 Résultats obtenus : Méthode gaussienne

En visualisant des prédictions j'ai vu des cas types tels qu'illustré ci-dessous :

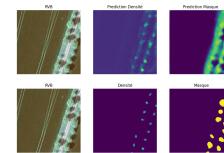
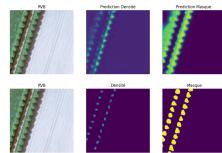


Fig. 2.1 : Méthode gausienne : Exemple Fig. 2.2 : Méthode gausienne : Exemple
1 2

Dans les résultats obtenus avec la méthode gaussienne, on observe que la prévision de la carte de densité n'est pas précise pour l'exemple 1, mais est meilleure pour l'exemple 2. En revanche, la prévision du masque n'est pas parfaite, car la segmentation des arbres déborde sur l'arrière-plan.

2.2 Résultats obtenus : Méthode euclidienne

En visualisant des prédictions j'ai vu des cas types tels qu'illustré ci-dessous :

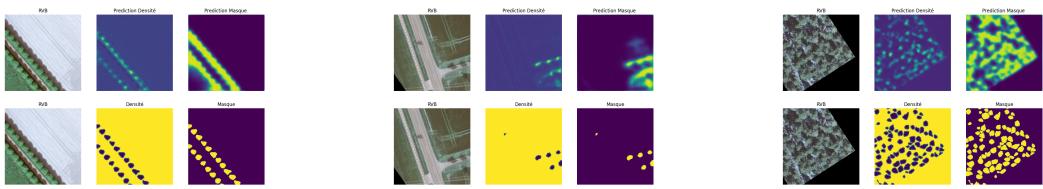


Fig. 2.3 : Méthode Euclidienne

Les résultats obtenus avec la méthode euclidienne sont plus satisfaisants que ceux obtenus avec la méthode gaussienne. On constate que la prédiction de la carte de densité est quasiment identique. En ce qui concerne la prédiction du masque, on observe une segmentation plus précise des arbres. Cependant, lorsque les arbres sont très proches, la segmentation éprouve des difficultés à les identifier individuellement, mais la carte de densité permet cette distinction.

2.3 Comparaison sur les prétraitements

En résumé, les résultats montrent que la méthode euclidienne offre généralement une meilleure performance que la méthode gaussienne pour le calcul de la carte de densité. La carte de densité joue un rôle critique en permettant de compenser les limites de la segmentation du masque, surtout lorsque les arbres sont très proches les uns des autres.

C'est pourquoi j'ai opté pour conserver la méthode euclidienne dans l'implémentation de mon modèle, car elle produit des résultats plus précis.

3 Résultats obtenus

Dans cette section, nous présentons sous forme de tableau l'évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle UNet.

- **Première ligne :** Perte de densité (MSE)
- **Deuxième ligne :** Perte de masque (Binary Cross-Entropy)
- **Troisième ligne :** Densité (RMSE)
- **Quatrième ligne :** Masque (Dice Loss)

Pour évaluer le comptage des arbres, j'ai appliqué un seuil de fiabilité de 0,8 aux masques prédits pour les binariser. Ensuite j'ai utilisé la fonction label qui identifie et étiquette les régions connectées distinctes dans une image binaire, permettant ainsi de compter le nombre d'arbre.

Nous visualiserons également les prédictions du modèle sur des données de test qu'il n'a jamais vues auparavant.

3.1 Données Opensource

Les résultats ci-dessous montrent une diminution régulière des pertes de densité (MSE) et de masque (Binary Crossentropy) pour les ensembles d'entraînement et de validation, avec des différences minimales, indiquant un bon apprentissage. Cependant, les fluctuations observées dans les courbes de validation pour le RMSE et la DiceLoss suggèrent un potentiel surajustement.

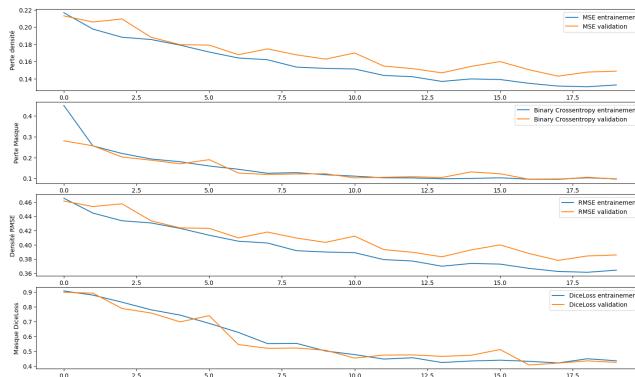


Fig. 3.1 : Données Opensource : Évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle Unet

Les résultats ci-dessous montrent que les prédictions de densité et de masque du modèle Unet montrent une bonne correspondance générale avec les données réelles. Cependant, les variations observées indiquent des opportunités d'amélioration.

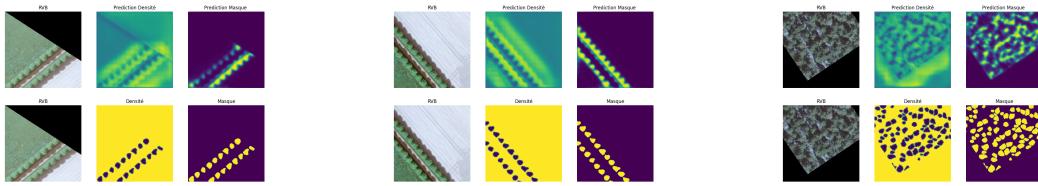


Fig. 3.2 : Données OpenSource : Exemples de Visualisation des prédictions comparées aux résultats attendus

Le modèle a correctement identifié le nombre d’arbres dans 70 % des cas, en se basant sur le jeu de données OpenSource.

Le MAE étant égal à 7 signifie que, en moyenne, mes prédictions diffèrent de 7 arbres par rapport aux valeurs réelles.

3.2 Données TENBS

Le modèle présenté dans cette section a été optimisé (fine-tuned) en se basant sur le modèle pré-entraîné avec les données OpenSource.

Les résultats montrent les pertes d’entraînement et de validation pour un modèle sur 40 époques. Globalement, toutes les pertes diminuent rapidement dans les premières époques, puis se stabilisent. La perte de validation est souvent inférieure ou similaire à la perte d’entraînement, ce qui suggère une bonne généralisation du modèle. Les pertes pour la densité (MSE et RMSE) et pour le masque (Binary Crossentropy et DiceLoss) montrent des tendances cohérentes, indiquant que le modèle apprend efficacement sans sur-apprentissage significatif.

Les prédictions de densité et de masque du modèle sont visuellement proches des vérités terrain, indiquant que le modèle fonctionne bien. Les prédictions de densité capturent les variations visibles dans les images RVB, et les prédictions de masque segmentent efficacement les zones d’intérêt. Le modèle démontre ainsi une bonne capacité de généralisation et de précision.

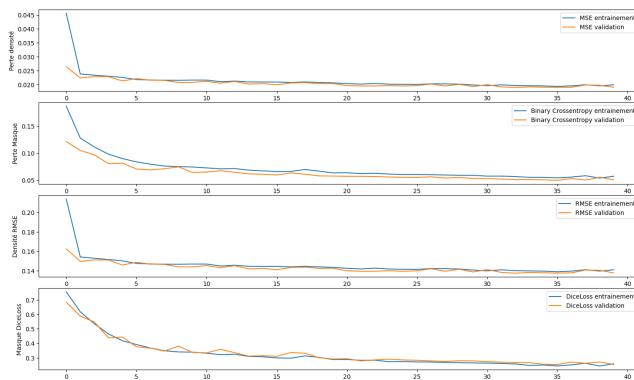


Fig. 3.3 : Données TENBS : Évolution des différentes pertes et métriques pendant l’entraînement et la validation du modèle Unet

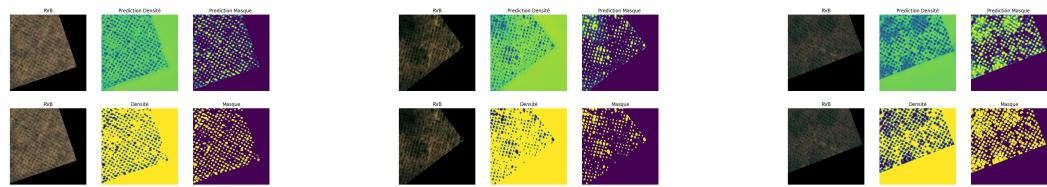


Fig. 3.4 : Données TENBS : Exemples de Visualisation des prédictions comparées aux résultats attendus

Le modèle a correctement identifié le nombre d’arbres dans 73 % des cas, sur le jeu de données TENBS.

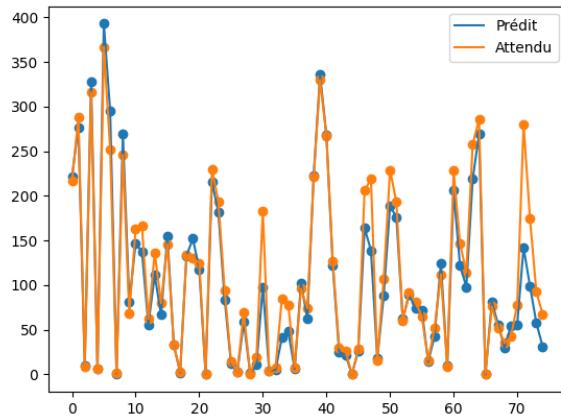


Fig. 3.5 : Comparaison entre les Valeurs Prédites et Attendues TENBS

Le MAE étant égal à 16 signifie que, en moyenne, mes prédictions diffèrent de 16 arbres par rapport aux valeurs réelles.

3.3 Données synthétiques

J'ai générée des images synthétiques pour les ensembles de données OpenSource et TENBS, puis j'ai réentraîné le modèle pré-entraîné en utilisant ces données.

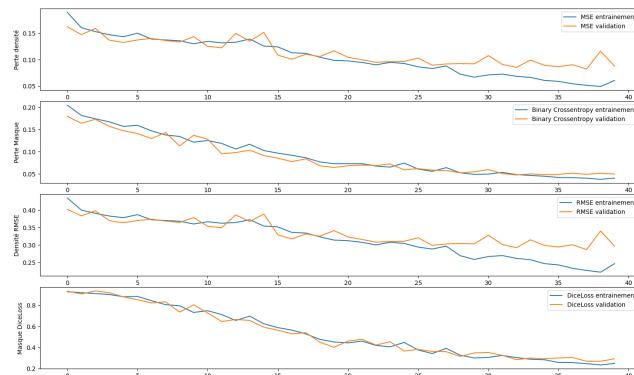


Fig. 3.6 : Données Synthétiques : Évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle Unet

On constate que le modèle converge efficacement avec les données synthétiques.

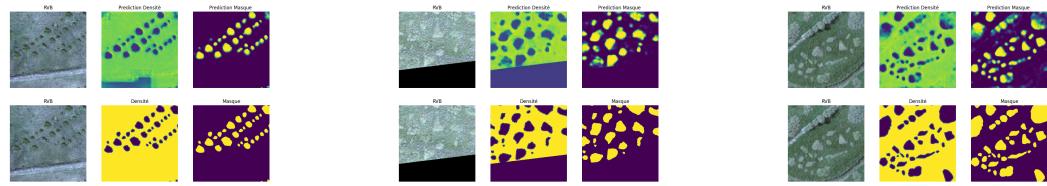


Fig. 3.7 : Données Synthétique Opensource : Exemples de Visualisation des prédictions comparées aux résultats attendus

Les résultats des prédictions sur les données synthétiques sont presque identiques. Le modèle a correctement identifié le nombre d'arbres dans 80 % des cas, en se basant uniquement sur des données synthétiques.

J'ai utilisé le modèle pré-entraîné sur les ensembles de données OpenSource, TENBS et des données synthétiques, en appliquant les mêmes jeux de tests que pour les modèles précédemment évalués. Les résultats obtenus sont les suivants :

- **OpenSource** : Le modèle détecte le nombre d'arbres avec une précision de 74% avec un MAE de 4.
- **TENBS** : Le modèle détecte le nombre d'arbres avec une précision de 40% avec un MAE de 64.

Les résultats révèlent que le modèle pré-entraîné montre une amélioration pour les données OpenSource, avec une précision de 70% par rapport à 74% précédemment, tandis qu'il obtient 40% de précision sur les données TENBS, comparé à 73% auparavant. Cette variation suggère une meilleure adaptation aux données OpenSource, mais indique également que le modèle a des difficultés accrues avec les données synthétiques TENBS

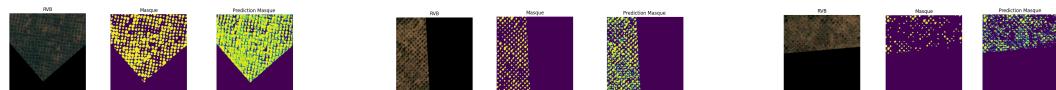


Fig. 3.8 : Tests sur données TENBS avec M4 : Exemples de Visualisation des prédictions comparées aux résultats attendus

Lorsqu'on observe les cas de mauvaise précision, on constate qu'ils sont liés à des arbres trop rapprochés et à des taches au sol que le modèle confond avec des buissons, de la terre et des ombres.

4 Déduction globales

Modèle	Composition	Précision	MAE
M1	Opensource	70 %	7
M2	M1 + TENBS	73 %	16
M3	M2 + Synthétique Opensource	74 %	4
M4	M2 + Synthétique TENBS	40 %	63

Fig. 4.1 : Bilan résultats obtenues

L'analyse des résultats montre que :

- Le modèle M1, entraîné uniquement sur 2 254 images aériennes OpenSource, obtient une précision de 70%. Les images aériennes Opensource permettent offrent une bonne base pour la détection des arbres.
- Le modèle M2, qui est une version fine-tunée de M1 avec 750 images satellites TENBS, montre une légère baisse de précision à 73%. La baisse de performance peut être due aux différences significatives entre les images aériennes et satellites, introduisant des variations qui compliquent l'apprentissage.
- Le modèle M3, fine-tuné avec 1 451 images synthétiques dérivées des images OpenSource, montre une amélioration notable avec une précision de 74%. Cela indique que les images synthétiques ont aidé le modèle à mieux généraliser et améliorer ses performances, en fournissant des exemples supplémentaires pertinents.
- Le modèle M4, fine-tuné avec 750 images synthétiques dérivées des images satellites TENBS, montre une baisse significative de la précision à 40%. Cela suggère que les données synthétiques TENBS ne sont pas suffisamment représentatives pour améliorer le modèle, et a introduit des caractéristiques non pertinentes pour la tâche de détection des arbres.

Ces résultats soulignent l'importance de la qualité et de la pertinence des données utilisées pour l'entraînement des modèles de détection. Les images aériennes et les images synthétiques dérivées des données aériennes sont plus efficaces que les

images satellites pour cette tâche. Une approche future pourrait impliquer l'utilisation de combinaisons plus équilibrées de données aériennes et satellitaires, ainsi qu'une exploration plus approfondie des images synthétiques, pour optimiser les performances du modèle.

Chapitre 6

Conclusion

Durant ce stage complet et enrichissant au sein de l'entreprise TotalEnergies, je suis ravie de partager les enseignements et les accomplissements qui ont marqué cette expérience passionnante dans le domaine du traitements d'images et des réseaux de neurone convolutif.

Durant ces six mois, j'ai eu l'opportunité de mettre en pratique et de renforcer mes compétences en vision par ordinateur en travaillant sur les thématiques suivantes : redimensionnement d'images, normalisation des pixels, techniques d'augmentation de données, génération d'images synthétiques, ainsi que la manipulation de réseaux de neurones convolutif pour la segmentation d'objets dans les images.

J'ai pu mettre en pratique les connaissances théoriques et pratiques acquises au cours de ma formation universitaire et les adapter aux problématiques réelles de l'entreprise. J'ai appris à travailler efficacement au sein d'une équipe multidisciplinaire, à l'écoute et à la compréhension du besoins métier, à planifier la prestation dans les six mois, à communiquer mes idées de manière claire et à gérer les priorités dans un environnement dynamique. Les résultats obtenus sont également gratifiants en seulement six mois.

L'apprentissage automatique (DeepLearning) est une discipline très empirique et complexe. Elle nécessite une grande expérience pratique. Le projet peut encore être amélioré et évoluer :

- Changer encore l'architecture,
- Augmenter le jeu de données et leur qualité,
- Tuillage par zone d'intérêts,
- Continuer de faire varier les hyper-paramètres,
- Essayer d'autres fonctions de pertes et d'optimisation,

- Comparer la génération d'images synthétiques actuelle avec les possibilités apportées par les IA génératives.

La mise au point d'un réseau de neurone de segmentation et comptage d'arbres nécessite du temps. Il est toujours en développement conjointement chez Google et suivi par la R&D de TotalEnergies.

Ce stage chez TotalEnergies a été une expérience formatrice. Il a renforcé ma conviction de carrière en tant que Data Scientiste et m'a donné l'assurance nécessaire pour aborder avec confiance les défis futurs. Je tiens à exprimer ma gratitude envers toute l'équipe qui m'a accueilli et guidé ainsi qu'à mon Université Paris 8 pour l'ensemble des connaissances et projets réalisés qui m'ont permis de pouvoir produire dans ces délais. Je reste enthousiaste à l'idée de continuer à apprendre et à contribuer dans ce domaine en constante évolution.

Glossaire

TENBS	TotalEnergies Nature Based Solutions
RD	Recherche et Développement
GES	Gaz à effet de serre
AFOLU	Agriculture, Foresterie et Autres Usages des terres
Unet	Réseau de neurones à convolution
TCDD	Tree Crown Delineation Detection
FCN	Fully Connected Network
RoI	Region of Interest
ALIGN	RoI Align

Table des figures

1.1	Logo du projet GreenMapper	14
2.1	Logo TotalEnergies	14
2.2	Présence de TotalEnergies dans les différentes régions du monde . .	15
2.3	Chiffre d'affaire de TotalEnergies	16
3.1	Organisation TotalEnergies	17
5.1	Organisation TENBS	20
5.2	Organisation OneTech	21
5.3	Parties prenantes du projet GreenMapper	22
7.1	Etapes du stage	24
3.1	Préparation des données	31
3.2	Le processus de télédétection	32
3.3	Logo SDFI	33
3.4	Logo NLS	33
3.5	Schéma d'acquisition de parcelles par drone	34
3.6	Images satellites et images drones du projet TENBS	35
4.1	Donnée du Danemark	37
4.2	Donnée de la Finlande	38
4.3	Données diverses	38
5.1	Création d'une image couleur	40
5.2	Création d'une image masque	41
5.3	Création d'une carte de densité	41
3.1	Modèle Unet de l'article	47
3.2	Formule pour le comptage d'arbres	48
3.3	Résultats du Modèle Unet	49

3.4	Résultat de l'article du Modèle Unet	50
3.5	Modèle Mask R-CNN de l'article	51
3.6	Forêt synthétique de l'article	52
3.7	Résultats des mesures d'évaluation pour toutes les couronnes d'arbres détectées par Mask R-CNN	52
3.8	Résultat de la segmentation du Mask R-CNN	53
3.9	Modèle de YOLOv5	53
3.10	Exemples d'augmentation des données de l'article Yolov5	54
3.11	Résultat de l'article du Modèle YOLOv5	54
3.12	Résultat de l'article du Modèle YOLOv5	55
4.1	Formule MSE	55
4.2	Formule binary crossentropy	56
1.1	Etapes du système réalisé	65
2.1	Visualisation des données	66
2.2	Schéma de reconstitution des données	67
3.1	Formule de normalisation	67
3.2	Gausienne	68
3.3	Euclidienne	69
3.4	Schéma de l'augmentation de données par tuiles	70
3.5	Augmentation des données	71
4.1	Les étapes de la génération d'images synthétiques	72
4.2	Exemple d'arrière-plan pour image synthétiques 1	73
4.3	Exemple d'arrière-plan pour image synthétiques 2	73
4.4	Exemple d'arbre pour image synthétiques	73
4.5	Image du masque associé à l'arbre	73
4.6	Formule alpha blending	75
4.7	Image d'arrière-plan	75
4.8	Image synthétique	75
4.9	Image d'arrière-plan	76
4.10	Image synthétique	76
4.11	Image d'arrière-plan	76
4.12	Image synthétique	76
4.13	Augmentation des données avec images synthétiques	76

2.1	Méthode gausienne : Exemple 1	82
2.2	Méthode gausienne : Exemple 2	82
2.3	Méthode Euclidienne	83
3.1	Données Opensource : Évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle Unet	84
3.2	Données Opensource : Exemples de Visualisation des prédictions comparées aux résultats attendus	85
3.3	Données TENBS : Évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle Unet	86
3.4	Données TENBS : Exemples de Visualisation des prédictions comparées aux résultats attendus	86
3.5	Comparaison entre les Valeurs Prédites et Attendues TENBS	87
3.6	Données Synthétiques : Évolution des différentes pertes et métriques pendant l'entraînement et la validation du modèle Unet	87
3.7	Données Synthétique Opensource : Exemples de Visualisation des prédictions comparées aux résultats attendus	88
3.8	Tests sur données TENBS avec M4 : Exemples de Visualisation des prédictions comparées aux résultats attendus	88
4.1	Bilan résultats obtenues	89

Table des matières

Remerciements	5
Introduction	7
I Problématique et état de l'art	9
1 Contexte de résolution du problème	13
1 Introduction	14
2 Entreprise	14
3 Gouvernance	16
4 Les services	17
4.0.1 TENBS	17
4.0.2 R&D	18
5 Les équipes	19
5.1 Equipe TENBS	19
5.2 Equipe R&D	21
5.3 Autres parties prenantes	21
6 Répartition du travail	22
7 La démarche et Planning	24
8 Conclusion	25
2 Le problème à résoudre	27
1 Objectif métier	28
2 Objectif technique	29
3 Données	29

3.1	Listes des données	29
3.2	Acquisition des données	31
3.2.1	Imagerie satellite	31
3.2.2	Imagerie par drone	34
3.2.3	Outils pour le Labelling	34
4	Analyse des données	36
4.1	Inconvénients pour l'acquisition	36
4.2	Les données en quelques chiffres	37
4.2.1	Données du Danemark	37
4.2.2	Données de la Finlande	37
4.2.3	Données de TotalEnergies	38
4.3	Format multiple	38
5	Ingénierie des caractéristiques	39
5.1	Élimination des données manquantes	39
5.2	Données à reconstituer	39
5.2.1	Image RVB	39
5.2.2	Image Masque	40
5.2.3	Carte de densité	41
6	Augmentation des données	42
7	Décomposition du problème	42
8	Conclusion	43
3	État de l'art : Data science pour le comptage et la segmentation d'objets dans les images	45
1	Introduction	46
2	Prétraitement et traitement des données	46
2.1	Techniques de Transformation d'Images	46
2.2	Génération d'Images Synthétiques	46
3	Travaux connexes	47
3.1	Article : Unet	47
3.2	Article : Mask R-CNN	51
3.3	Article : YOLOv5	52
3.4	SAM	54
3.5	Comparaison	54

4	Evaluation des résultats	55
5	Conclusion	57
II	Système réalisé	59
4	Implémentation du système	63
1	Introduction	65
2	Collecte et Reconstitution des données	66
2.1	Visualisation des données	66
2.2	Reconstitution des données	66
3	Prétraitement	67
3.1	Normalisation	67
3.2	Calcul de la carte de densité	68
3.2.1	Méthode 1 : Noyau Gaussien	68
3.2.2	Méthode 2 : Transformée de Distance Euclidienne	69
3.2.3	Comparaison	69
3.3	Traitements des données	69
4	Générations d'images synthétiques	71
4.1	Initialisation	73
4.2	Sélection des images de référence	73
4.3	Positionnement	74
4.4	Création de Masques et Densités pour Arbres Positionnés .	74
4.5	Data-augmentation	74
4.6	Combinaison	74
4.7	Résultats	75
5	Séparation des données	76
6	Algorithme de segmentation et comptage : Unet	77
6.1	Structure du Modèle	77
6.1.1	Entrée	77
6.1.2	Encoder : Blocs de Convolution et Pooling	77
6.1.3	Bloc Bottleneck	78
6.1.4	Decoder : Blocs de Transpose Convolution et Concatenation	78
6.1.5	Sorties	78

6.1.6	Optimiseur Adam Personnalisé	78
6.1.7	Batch Size et Époques	79
7	Évaluation du modèle	79
7.1	Prédiction de Densité :	79
7.2	Segmentation des Polygones :	79
7.3	Comptage :	80
8	Conclusion	80
5	Expérimentations et résultats	81
1	Introduction	82
2	Sélection de la méthode de prétraitements	82
2.1	Résultats obtenus : Méthode gaussienne	82
2.2	Résultats obtenus : Méthode euclidienne	82
2.3	Comparaison sur les prétraitements	83
3	Résultats obtenus	83
3.1	Données Opensource	84
3.2	Données TENBS	85
3.3	Données synthétiques	87
4	Déduction globales	89
6	Conclusion	91
Conclusion		91
Glossaire		93
Table des figures		95
Table des matières		99